TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN

DƯƠNG HOÀNG KHANG

MSSV: 223952

LỚP: DH22KPM01

TÊN ĐỀ TÀI

MÔ HÌNH AI HỖ TRỢ CHẨN ĐOÁN BỆNH DA LIỄU TỪ ẢNH DA

ĐỒ ÁN CƠ SỞ

Ngành: Kỹ Thuật Phần Mềm

Mã số ngành: 7480103

03/2026

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ

KHOA CÔNG NGHỆ THÔNG TIN

DƯƠNG HOÀNG KHANG

MSSV: 223952

LỚP: DH22KPM01

TÊN ĐỀ TÀI

MÔ HÌNH AI HỖ TRỢ CHẨN ĐOÁN BỆNH DA LIỄU TỪ ẢNH DA

ĐỒ ÁN CƠ SỞ

Ngành: Kỹ Thuật Phần Mềm

Mã số ngành: 7480103

GIẢNG VIÊN HƯỚNG DẪN

TRẦN VĂN THIỆN

LỜI CẢM ƠN

Em xin gửi lời cảm ơn chân thành đến thầy **Trần Văn Thiện**, giảng viên Khoa Công nghệ thông tin - trường Đại học Nam Cần Thơ đã hướng dẫn để chúng em hoàn thành đồ án này.

Em cũng xin chân thành cảm ơn các thầy cô trong trường đại học Nam Cần Thơ nói chung và các thầy cô khoa công nghệ thông tin nói riêng đã dạy em những kiến thức về các môn đại cương cũng như các môn chuyên ngành, giúp em có được cơ sở lý thuyết vững vàng và tạo điều kiện giúp đỡ em trong suốt quá trình học tập.

Mặc dù, chúng em đã có rất nhiều cố gắng nỗ lực để hoàn thành đồ án nhưng vẫn không tránh khỏi những thiếu sót. Kính mong nhận được sự đóng góp ý kiến của quý thầy cô.

Cần Thơ, ngày tháng năm 2026

Người thực hiện

Dương Hoàng Khang

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

Cần Thơ, ngày .... tháng .... năm 2026

Giảng Viên Hướng Dẫn

Trần Văn Thiện

MỤC LỤC

CHƯƠNG 1 GIỚI THIỆU 1
1.1. Ứng Dụng Trí Tuệ Nhân Tạo Trong Y Tế Là Gì? 1
1.2. Bài Toán Chẩn Đoán Bệnh Da Liễu 1
1.2.1. Thực trạng các bệnh lý da liễu hiện nay 1
1.2.2. Khó khăn trong công tác khám sàng lọc lâm sàng 1
1.2.3. Mục tiêu và giải pháp của mô hình hỗ trợ chẩn đoán bệnh da liễu 2
1.3. Tình Hình Nghiên Cứu Và Các Công Trình Liên Quan 2
1.3.1. Tình hình nghiên cứu trên thế giới 2
1.3.2. Hạn chế của các nghiên cứu trước và đề xuất của đồ án 3
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT 4
2.1. Cơ Sở Dữ Liệu & Công Nghệ 4
2.1.1. So sánh cơ sở dữ liệu SQL và NoSQL 4
2.1.2. Kiến trúc Web API với FastAPI 5
2.2. Cơ Sở Trí Tuệ Nhân Tạo & Xử Lý Ảnh Y Khoa 6
2.2.1. Mạng Nơ-ron Tích chập (CNN) trong Thị giác máy tính 6
2.2.2. Kiến trúc EfficientNet và Phương pháp Tỷ lệ Kép (Compound Scaling) 6
2.2.3. Thuật toán DullRazor trong tiền xử lý da liễu 7
2.2.4. Phân đoạn hình ảnh với YOLOv8-Segmentation 7
2.2.5. Giải quyết mất cân bằng dữ liệu bằng Asymmetric Loss 8
2.2.6. Trực quan hóa và Giải thích (Explainable AI) với Grad-CAM 9
CHƯƠNG 3 PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH MEDAI DERMATOLOGY 10
3.1. Phân Tích Yêu Cầu Hệ Thống 10
3.1.1. Yêu Cầu Chức Năng 10
3.1.2. Yêu Cầu Phi Chức Năng 10
3.2. Mô Hình Hóa Hệ Thống 11
3.2.1. Sơ đồ Phân rã chức năng (BFD) 11
3.2.2. Sơ đồ Ca sử dụng (Use Case) 11
3.2.3. Sơ đồ Hoạt động (Activity Diagram) 12
3.2.4. Sơ đồ Tuần tự (Sequence Diagram) 14
3.2.5. Luồng hậu xử lý và Cảnh báo rủi ro y khoa 15
3.3. Thiết Kế Cơ Sở Dữ Liệu 16
3.3.1. Sơ đồ Thực thể kết hợp (ERD - Mức logic) 16
3.3.2. Đặc tả chi tiết các bảng dữ liệu 17
3.4. Kiến trúc triển khai phân tán (Decoupled Architecture) 19

CHƯƠNG 4 KẾT QUẢ THỰC NGHIỆM VÀ GIAO DIỆN HỆ THỐNG 21
4.1. Xây dựng và Chuẩn bị Bộ dữ liệu thực nghiệm 21
4.1.1. Các nguồn dữ liệu thành phần 21
4.1.2. Phương pháp tích hợp và đồng bộ hóa dữ liệu 21
4.1.3. Đặc tả kết quả bộ dữ liệu tổng hợp 22
4.2. So sánh hệ thống với các công trình liên quan (SOTA) 22
4.3. Quá trình tinh chỉnh và Tiến hóa của Mô hình 23
4.4. Phân tích qua các chỉ số trực quan 26
4.4.1. Đánh giá qua Ma trận nhầm lẫn (Confusion Matrix) 26
4.4.2. Đánh giá qua Đường cong học tập (Learning Curves) 27
4.4.3. Minh bạch hóa dự đoán với bản đồ nhiệt Grad-CAM 27
4.5. Giao Diện Hệ Thống Thực Tế 28
4.5.1. Giao Diện Đăng Ký Tài Khoản 28
4.5.2. Giao Diện Đăng Nhập 28
4.5.3. Giao Diện Trang Chủ 29
4.5.4. Giao Diện Chẩn Đoán Bệnh 30
4.5.5. Giao Diện Nhận Kết Quả Chẩn Đoán 30
4.5.6. Giao Diện Xem Lịch Sử Chẩn Đoán 32
CHƯƠNG 5 KẾT LUẬN 33
5.1. Kết Quả Đạt Được 33
5.2. Hướng Phát Triển 34
TÀI LIỆU THAM KHẢO 35
PHỤ LỤC 36
1. Địa chỉ truy cập hệ thống (Live Demo) 36
2. Kiến trúc triển khai 36
3. Hướng dẫn triển khai production 36
3.1 Backend (Hugging Face Spaces) 36
3.2 Frontend (VPS) 36
4. Cài đặt môi trường local 36
5. Hướng dẫn sử dụng hệ thống 37

DANH SÁCH BẢNG

Bảng 3.1 Bảng Users……17
Bảng 3.2 Bảng Diseases……17
Bảng 3.3 Bảng Diagnosis_History……18
Bảng 3.4 Bảng Expert_Feedbacks……19
Bảng 4.1 Bảng so sánh hiệu năng và tính năng với các nghiên cứu liên quan ……23

DANH SÁCH HÌNH

Hình 3.1 Sơ đồ Phân rã chức năng (BFD) ……..11

Hình 3.2 Sơ đồ Ca sử dụng (Use Case Diagram) ……12

Hình 3.3 Sơ đồ Hoạt động quy trình chẩn đoán và thu thập phản hồi……..…13

Hình 3.4 Sơ đồ Tuần tự giao tiếp các thành phần hệ thống……15

Hình 3.5 Sơ đồ Thực thể Kết hợp (ERD) mức logic……16

Hình 4.1 Biểu đồ thể hiện sự cải thiện độ chính xác qua các phiên bản mô hình……...…24

Hình 4.2 Biểu đồ đường cong hàm mất mát (Validation Loss) qua các phiên bản mô hình. ……...25

Hình 4.3 Biểu đồ độ chính xác kiểm định (Validation Accuracy) qua các phiên bản mô hình. ……25

Hình 4.4 Ma trận nhầm lẫn (Confusion Matrix) đánh giá trên tập kiểm thử……26

Hình 4.5 Sơ đồ đường cong học tập (Learning Curves) của mô hình EfficientNet-B4 V3.0. ……..…27

Hình 4.6 Trực quan hóa vùng tổn thương qua Grad-CAM……..……27

Hình 4.7 Giao diện đăng ký tài khoản……..28

Hình 4.8 Giao diện đăng nhập……..29

Hình 4.9 Giao diện trang chủ……...……29

Hình 4.10 Giao diện chẩn đoán bệnh……...……30

Hình 4.11 Giao diện nhận kết quả chẩn đoán……..31

Hình 4.12 Giao diện xem lịch sử chẩn đoán……32

DANH MỤC TỪ VIẾT TẮT

1. ANN: Artificial Neural Network
2. AI: Artificial Intelligence
3. API: Application Programming Interface
4. CNN: Convolutional Neural Network
5. LLM: Large language model
6. SQL: Structured Query Language

CHƯƠNG 1
GIỚI THIỆU

1.1. Ứng Dụng Trí Tuệ Nhân Tạo Trong Y Tế Là Gì?

Trong kỷ nguyên công nghiệp 4.0, Trí tuệ Nhân tạo (Artificial Intelligence - AI) đã vượt ra khỏi phạm vi của các phòng thí nghiệm khoa học máy tính để bước vào ứng dụng thực tiễn trong nhiều lĩnh vực, đặc biệt là y tế và chăm sóc sức khỏe. Ứng dụng AI trong y tế là việc sử dụng các thuật toán phức tạp và phần mềm học máy (Machine Learning) để mô phỏng nhận thức của con người trong việc phân tích, diễn giải và hiểu các dữ liệu y tế phức tạp.

Cụ thể hơn, phân nhánh Học sâu (Deep Learning) và Thị giác máy tính (Computer Vision) đang tạo ra một cuộc cách mạng trong lĩnh vực chẩn đoán hình ảnh (Radiology & Dermatology). Các mạng nơ-ron tích chập (Convolutional Neural Networks - CNN) có khả năng tự động trích xuất các đặc trưng tiềm ẩn từ hình ảnh X-quang, MRI, hay ảnh chụp bề mặt da mà mắt thường khó lòng nhận biết.

Sự hiện diện của hệ thống AI không nhằm mục đích thay thế bác sĩ, mà đóng vai trò như một hệ thống Chẩn đoán Hỗ trợ bằng Máy tính (Computer-Aided Diagnosis - CAD). AI hoạt động như một "người đồng nghiệp thứ hai" không biết mệt mỏi, giúp rà soát chéo kết quả, giảm thiểu sai sót do yếu tố chủ quan hoặc áp lực công việc, từ đó nâng cao chất lượng khám chữa bệnh và tối ưu hóa thời gian vàng trong điều trị.

1.2. Bài Toán Chẩn Đoán Bệnh Da Liễu

1.2.1. Thực trạng các bệnh lý da liễu hiện nay

Theo Tổ chức Y tế Thế giới (WHO), các bệnh lý về da là một trong những dạng bệnh phổ biến nhất trên toàn cầu, ảnh hưởng đến hàng tỷ người ở mọi lứa tuổi. Dù đa số các bệnh da liễu (như chàm, mụn trứng cá, viêm da cơ địa) không gây tử vong ngay lập tức, nhưng chúng làm suy giảm nghiêm trọng chất lượng cuộc sống. Đặc biệt nguy hiểm là các khối u ác tính trên da, điển hình là ung thư da tế bào hắc tố (Melanoma). Nếu không được phát hiện và can thiệp ở giai đoạn đầu, Melanoma có tỷ lệ di căn nhanh và tỷ lệ tử vong rất cao.

1.2.2. Khó khăn trong công tác khám sàng lọc lâm sàng

Trong thực tiễn y khoa hiện nay, việc chẩn đoán các bệnh lý da liễu vẫn phụ thuộc chủ yếu vào kỹ năng quan sát lâm sàng bằng mắt thường hoặc sử dụng

kính lúp chuyên dụng (Dermoscopy) của các bác sĩ chuyên khoa. Quy trình này đang gặp phải ba thách thức lớn:

- Sự thiếu hụt nguồn nhân lực chuyên môn cao: Việc phân biệt các tổn thương da có hình thái giống nhau (ví dụ: một nốt ruồi lành tính và một nốt hắc tố ác tính giai đoạn sớm) đòi hỏi bác sĩ phải có nhiều năm kinh nghiệm thực tiễn.
- Áp lực quá tải tại các cơ sở y tế: Tại các bệnh viện tuyến đầu, số lượng bệnh nhân đổ về mỗi ngày là rất lớn. Thời gian trung bình để một bác sĩ thăm khám cho một bệnh nhân bị rút ngắn đáng kể, làm tăng nguy cơ bỏ lọt các dấu hiệu bệnh lý nguy hiểm (Âm tính giả).
- Trở ngại về địa lý và chi phí: Bệnh nhân ở các vùng sâu, vùng xa thường gặp khó khăn trong việc tiếp cận các chuyên gia da liễu giỏi, dẫn đến tâm lý chủ quan, để bệnh tiến triển nặng mới đi khám.

1.2.3. Mục tiêu và giải pháp của mô hình hỗ trợ chẩn đoán bệnh da liễu

Từ những thực trạng nêu trên, việc nghiên cứu và phát triển một giải pháp công nghệ hỗ trợ chẩn đoán từ xa là vô cùng cấp thiết. Đề tài "Mô hình AI hỗ trợ chẩn đoán bệnh da liễu" được thực hiện nhằm giải quyết trực tiếp bài toán này.

Dự án hướng tới việc xây dựng một hệ thống phần mềm toàn diện, cho phép người dùng (bệnh nhân hoặc bác sĩ cơ sở) dễ dàng tải lên hình ảnh vùng da bị tổn thương chụp từ thiết bị di động. Ngay lập tức, lõi Trí tuệ Nhân tạo (sử dụng cấu trúc mạng tiên tiến EfficientNet kết hợp cùng luồng tiền xử lý YOLOv8 và DullRazor) sẽ phân tích hình ảnh, khoanh vùng tổn thương và đưa ra dự đoán xác suất mắc phải đối với 24 nhóm bệnh da liễu phổ biến nhất.

Hệ thống AI không chỉ cung cấp kết quả chẩn đoán nhanh chóng, chính xác (hỗ trợ phân luồng bệnh nhân hiệu quả), mà còn minh bạch hóa quá trình suy luận của AI thông qua công nghệ bản đồ nhiệt Grad-CAM, giúp các bác sĩ chuyên khoa có thêm cơ sở khoa học vững chắc trước khi đưa ra phác đồ điều trị cuối cùng.

1.3. Tình Hình Nghiên Cứu Và Các Công Trình Liên Quan

1.3.1. Tình hình nghiên cứu trên thế giới

Trong những năm gần đây, trí tuệ nhân tạo (AI), đặc biệt là học sâu (Deep Learning), đã được ứng dụng rộng rãi trong lĩnh vực y tế, trong đó có chẩn đoán bệnh da liễu từ hình ảnh. Nhiều nghiên cứu đã chứng minh rằng các mô

hình học sâu có khả năng hỗ trợ bác sĩ trong việc phát hiện và phân loại các bệnh về da với độ chính xác cao.

Một trong những công trình tiêu biểu trong lĩnh vực này là nghiên cứu của Andre Esteva và cộng sự (2017). Nghiên cứu này sử dụng mô hình mạng nơ-ron tích chập (CNN) để phân loại các bệnh ung thư da từ hình ảnh, đạt độ chính xác tương đương với bác sĩ da liễu trong một số trường hợp. Công trình này được xem là nền tảng quan trọng cho các nghiên cứu tiếp theo về chẩn đoán bệnh da liễu bằng trí tuệ nhân tạo.

Bên cạnh đó, vấn đề mất cân bằng dữ liệu (data imbalance) thường xảy ra trong các bộ dữ liệu y tế, khi số lượng mẫu của một số bệnh hiếm ít hơn đáng kể so với các bệnh phổ biến. Để giải quyết vấn đề này, Tal Ridnik và cộng sự (2021) đã đề xuất hàm mất mát Asymmetric Loss, nhằm cải thiện hiệu quả huấn luyện trong các bài toán phân loại nhiều nhãn với dữ liệu không cân bằng. Phương pháp này đã được áp dụng rộng rãi trong nhiều nghiên cứu về thị giác máy tính và có thể giúp nâng cao hiệu quả phân loại trong các ứng dụng chẩn đoán y khoa.

Ngoài ra, một số nghiên cứu gần đây cũng tập trung vào việc kết hợp nhiều mô hình hoặc sử dụng các kiến trúc mạng hiện đại để nâng cao hiệu quả phân loại bệnh da liễu. Ví dụ, nghiên cứu của Harshith S. và cộng sự (2025) đề xuất một phương pháp kết hợp giữa mô hình phát hiện đối tượng và mô hình phân loại để nhận dạng các bệnh da liễu từ hình ảnh. Các nghiên cứu khác cũng đã ứng dụng các kiến trúc mạng tiên tiến như Transformer hoặc các mô hình CNN cải tiến nhằm nâng cao khả năng trích xuất đặc trưng từ hình ảnh.

1.3.2. Hạn chế của các nghiên cứu trước và đề xuất của đồ án

Mặc dù đạt nhiều kết quả tích cực, các công trình hiện tại vẫn còn một số hạn chế như: phụ thuộc vào tập dữ liệu lý tưởng, xử lý hình ảnh thực tế (chứa nhiễu lông, tóc, phông nền) còn kém và yêu cầu tài nguyên tính toán lớn. Do đó, việc xây dựng các giải pháp có độ chính xác cao và tối ưu hiệu suất tính toán là rất cần thiết.

Kế thừa và khắc phục những hạn chế trên, đồ án đề xuất hệ thống AI hỗ trợ chẩn đoán bệnh da liễu MedAI Dermatology. Mô hình được xây dựng dựa trên mạng học sâu EfficientNet-B4 kết hợp luồng tiền xử lý nhiễu chuyên sâu, được huấn luyện trên các bộ dữ liệu lớn như DermNet, ISIC 2019 và PAD-UFES-20. Mục tiêu của hệ thống là phân loại 24 nhãn bệnh với độ chính xác lâm sàng cao, vận hành tối ưu tài nguyên và trực tiếp hỗ trợ bác sĩ đối chiếu chẩn đoán trong thực tế.

CHƯƠNG 2
CƠ SỞ LÝ THUYẾT

2.1. Cơ Sở Dữ Liệu & Công Nghệ

2.1.1. So sánh cơ sở dữ liệu SQL và NoSQL

SQL là viết tắt của "Structured Query Language", tức là Ngôn ngữ Truy vấn Cấu trúc. SQL là một ngôn ngữ chuẩn được sử dụng để truy vấn, quản lý và tương tác với cơ sở dữ liệu quan hệ. Nó cung cấp một tập hợp các câu lệnh để thực hiện các thao tác như truy vấn dữ liệu, chèn, cập nhật và xóa nội dung. Trong việc thiết kế kiến trúc phần mềm, định hình phương pháp lưu trữ dữ liệu là bước đi nền tảng. Hiện nay, có hai mô hình cơ sở dữ liệu thống trị là Cơ sở dữ liệu quan hệ (SQL) và Cơ sở dữ liệu phi quan hệ (NoSQL), mỗi loại được thiết kế để giải quyết những bài toán đặc thù khác nhau.

Cơ sở dữ liệu quan hệ (SQL): Cơ sở dữ liệu quan hệ (đại diện bởi MySQL, PostgreSQL, SQL Server) tổ chức dữ liệu dưới dạng các bảng (Tables) hai chiều gồm hàng và cột. Mô hình này yêu cầu dữ liệu phải tuân thủ nghiêm ngặt một lược đồ (Schema) đã được định nghĩa từ trước. Dữ liệu được bóc tách thành nhiều bảng để tránh dư thừa và liên kết với nhau qua các khóa, đòi hỏi hệ thống phải thực hiện các phép kết nối (JOIN) phức tạp khi truy vấn. Ưu điểm lớn nhất của SQL là đảm bảo tuyệt đối các thuộc tính ACID (Nguyên tử, Nhất quán, Độc lập, Bền vững), rất phù hợp cho các hệ thống giao dịch tài chính. Tuy nhiên, SQL thường bị hạn chế bởi sự cứng nhắc của lược đồ và khó khăn trong việc mở rộng hệ thống theo chiều ngang.

Cơ sở dữ liệu phi quan hệ (NoSQL): Ngược lại, sự bùng nổ của dữ liệu lớn (Big Data) đã thúc đẩy sự ra đời của NoSQL. Thay vì ép dữ liệu vào các khuôn mẫu bảng biểu cứng nhắc, NoSQL hỗ trợ lưu trữ dữ liệu phi cấu trúc hoặc bán cấu trúc dưới nhiều dạng như Key-Value, Graph, hay phổ biến nhất là dạng Tài liệu (Document-based như MongoDB). NoSQL sở hữu lược đồ động (Dynamic Schema), cho phép các bản ghi trong cùng một tập hợp có cấu trúc hoàn toàn khác nhau. Điều này giúp các nhà phát triển linh hoạt thêm bớt tính năng mà không lo ảnh hưởng đến dữ liệu cũ. Bên cạnh đó, NoSQL được thiết kế tối ưu cho việc mở rộng ngang trên các cụm máy chủ phân tán, mang lại hiệu năng đọc/ghi khổng lồ.

Lý do lựa chọn MongoDB cho hệ thống: Đối chiếu với bài toán của hệ thống chẩn đoán y khoa ứng dụng Trí tuệ Nhân tạo, việc lưu trữ các siêu dữ liệu sinh ra từ lõi Deep Learning đòi hỏi sự linh hoạt và tốc độ truy xuất cực cao.

Do đó, đề tài quyết định lựa chọn MongoDB làm hệ quản trị cơ sở dữ liệu chính với 3 lý do cốt lõi:

- Lưu trữ nguyên bản cấu trúc AI (Native JSON/BSON Storage): Kết quả suy luận từ lõi EfficientNet là một cấu trúc mảng lồng nhau phức tạp (bao gồm Top 3 bệnh lý, hệ số tự tin, tọa độ vùng bệnh, và đường dẫn Grad-CAM). MongoDB cho phép đóng gói trọn vẹn khối dữ liệu JSON này vào một Document duy nhất, loại bỏ hoàn toàn các phép JOIN nặng nề, giảm thiểu tối đa độ trễ.
- Khả năng tương thích với vòng đời MLOps: Quá trình huấn luyện AI là một chu kỳ liên tục. Khi nâng cấp mô hình (từ V1.0 lên V3.0) hoặc thêm các trường đánh giá phản hồi của bác sĩ, lược đồ động của MongoDB cho phép chèn thêm dữ liệu mới vào các phiên khám sau này mà không làm phá vỡ cấu trúc hồ sơ bệnh án cũ.
- Đồng bộ với hệ sinh thái Python/FastAPI: Lõi Backend của hệ thống được xây dựng bằng FastAPI, xử lý dữ liệu qua các model Pydantic (bản chất là các Dictionary của Python). Cấu trúc này ánh xạ tự nhiên 1-1 với định dạng BSON của MongoDB, tạo ra luồng dữ liệu xuyên suốt từ Frontend đến AI Core mà không cần các thư viện chuyển đổi trung gian rườm rà.

2.1.2. Kiến trúc Web API với FastAPI

Để kết nối cơ sở dữ liệu MongoDB với giao diện người dùng và lõi xử lý AI, hệ thống yêu cầu một tầng Backend mạnh mẽ.

Đề tài lựa chọn FastAPI – một Web Framework hiện đại, hiệu năng cao được phát triển bằng ngôn ngữ Python. FastAPI mang lại những giá trị cốt lõi cho hệ thống AI bao gồm:

- Hiệu suất ngang hàng NodeJS/Go: Nhờ xây dựng trên nền tảng Starlette (quản lý luồng web) và Pydantic (xác thực dữ liệu), FastAPI cung cấp tốc độ xử lý vượt trội.
- Xử lý bất đồng bộ (Asynchronous Programming): Trong các ứng dụng AI, quá trình mô hình PyTorch tính toán (Inference) thường mất từ 1 đến 3 giây. Việc sử dụng cơ chế async/await của FastAPI giúp máy chủ không bị treo (blocking) khi chờ AI phân tích, cho phép hệ thống tiếp nhận cùng lúc nhiều yêu cầu khám bệnh từ nhiều người dùng khác nhau.
- Tích hợp liền mạch với hệ sinh thái Khoa học dữ liệu: Do cùng chia sẻ ngôn ngữ Python, FastAPI có thể nạp (load) trực tiếp các mô hình

AI (TensorFlow/PyTorch) và xử lý mảng tính toán với NumPy, OpenCV mà không cần các cầu nối (Bridge) ngôn ngữ phức tạp.

2.2. Cơ Sở Trí Tuệ Nhân Tạo & Xử Lý Ảnh Y Khoa

2.2.1. Mạng Nơ-ron Tích chập (CNN) trong Thị giác máy tính

Mạng nơ-ron tích chập (Convolutional Neural Network - CNN) là cấu trúc lõi của hầu hết các mô hình nhận diện hình ảnh hiện đại. Khác với mạng nơ-ron truyền thống (ANN) yêu cầu dữ liệu đầu vào là các vector 1D làm mất đi cấu trúc không gian của ảnh, CNN giữ nguyên cấu trúc 2D/3D của điểm ảnh. Thuật toán hoạt động bằng cách sử dụng các ma trận bộ lọc (Kernels/Filters) trượt dọc theo bức ảnh để thực hiện phép toán Tích chập (Convolution). Quá trình này giúp mô hình tự động trích xuất các đặc trưng:

- Các lớp chập đầu tiên (Shallow Layers): Nhận diện các đặc trưng bậc thấp như đường thẳng, góc cạnh, và màu sắc của vùng viêm đỏ.
- Các lớp chập sâu (Deep Layers): Tổng hợp các đường nét thành các đặc trưng bậc cao như kết cấu vảy nến, hình thái bất đối xứng của nốt ruồi hay bờ viền của khối u hắc tố.

2.2.2. Kiến trúc EfficientNet và Phương pháp Tỷ lệ Kép (Compound Scaling)

Trong đồ án này, kiến trúc EfficientNet-B4 được lựa chọn làm mạng xương sống (Backbone). Trước khi EfficientNet ra đời, để tăng độ chính xác của một mô hình, các nhà khoa học thường mở rộng mạng theo một chiều duy nhất: tăng độ sâu (thêm nhiều lớp – như ResNet), tăng độ rộng (thêm nhiều kênh – như WideResNet), hoặc tăng độ phân giải ảnh đầu vào. Tuy nhiên, việc mở rộng đơn lẻ này nhanh chóng đạt đến điểm bão hòa và tiêu tốn tài nguyên khổng lồ.

EfficientNet giải quyết bài toán này bằng thuật toán Compound Scaling Method. Nó sử dụng một hệ số ϕ chung để tự động cân đối cả ba chiều: chiều sâu, chiều rộng và độ phân giải ảnh theo một tỷ lệ toán học nghiêm ngặt.

Cụ thể, phương pháp Compound Scaling định nghĩa bài toán mở rộng mạng thông qua các công thức sau:

$$d = \alpha^{\phi}, w = \beta^{\phi}, r = \gamma^{\phi}$$

Kèm theo điều kiện ràng buộc:

$$\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2,\ \alpha \geq 1,\ \beta \geq 1, \gamma \geq 1$$

Trong đó, α, β, γ là các hằng số được xác định thông qua quá trình grid search trên mô hình cơ sở (baseline). Biến số ϕ là hệ số mở rộng tổng thể do người dùng lựa chọn tùy theo tài nguyên phần cứng.

Việc bình phương β và γ xuất phát từ thực tế rằng chi phí tính toán (FLOPs) của mạng sẽ:

- tăng tuyến tính khi độ sâu d tăng
- nhưng tăng theo bình phương khi độ rộng w hoặc độ phân giải r tăng

Nhờ đó, EfficientNet-B4 đạt được độ chính xác vượt trội so với các mô hình thế hệ cũ, trong khi số lượng tham số nhẹ hơn đáng kể, phù hợp để triển khai trên môi trường Web Server có giới hạn VRAM.

2.2.3. Thuật toán DullRazor trong tiền xử lý da liễu

Nhiễu do lông và tóc trên bề mặt da là tác nhân chính gây ra sai số (Noise) cho các thuật toán Computer Vision. Hệ thống áp dụng thuật toán hình thái học DullRazor với quy trình 3 bước xử lý vi tính:

- Xác định vị trí lông: Ảnh màu RGB được chuyển sang ảnh xám (Grayscale). Sau đó, toán tử đóng hình thái học (Morphological Closing) kết hợp thuật toán Black-hat được áp dụng để làm nổi bật các cấu trúc dạng ống hẹp, dài và có màu tối (đặc điểm của sợi lông).
- Tạo mặt nạ (Masking): Thuật toán phân ngưỡng (Thresholding) nhị phân hóa các sợi lông này thành một mặt nạ (Pixel trắng là lông, pixel đen là da).
- Phục hồi ảnh (Inpainting): Thay vì chỉ xóa sợi lông để lại vệt đen, hệ thống dùng hàm nội suy Navier-Stokes để lấp đầy các điểm ảnh bị khuyết bằng cách mượn màu sắc và kết cấu (texture) của các vùng da lân cận, trả lại bề mặt tổn thương nguyên vẹn cho AI phân tích.

2.2.4. Phân đoạn hình ảnh với YOLOv8-Segmentation

Bên cạnh nhiễu bề mặt, nhiễu phông nền (Background) cũng là một bài toán hóc búa. YOLO (You Only Look Once) phiên bản v8 là mô hình học sâu State-of-the-Art về tốc độ và độ chính xác. Hệ thống sử dụng YOLOv8-Seg không chỉ để vẽ khung hộp chữ nhật (Bounding box) quanh vùng da bệnh, mà còn xuất ra một mặt nạ đa giác (Segmentation Mask) ôm sát ranh giới tổn thương. Kỹ thuật này giúp cắt bỏ hoàn toàn các vật thể thừa (thước đo, quần áo, thiết bị y tế), ép mô hình EfficientNet phải hội tụ sự chú ý 100% vào vết bệnh.

2.2.5. Giải quyết mất cân bằng dữ liệu bằng Asymmetric Loss

Trong thực tiễn y khoa, các bộ dữ liệu da liễu luôn đặc trưng bởi tính chất phân phối đuôi dài (Long-tail Distribution): Các bệnh lý lành tính (như mụn trứng cá, viêm da, nốt ruồi) có số lượng lên tới hàng vạn ảnh, trong khi các ca bệnh ung thư ác tính lại vô cùng khan hiếm. Nếu chỉ sử dụng hàm mất mát Cross-Entropy tiêu chuẩn, mô hình AI sẽ rơi vào "Nghịch lý độ chính xác" (Accuracy Paradox) – tức là có xu hướng luôn dự đoán "Không ung thư" để tối ưu hóa độ chính xác (Accuracy) tổng thể, dẫn đến việc bỏ lọt các ca bệnh nguy hiểm.

Để giải quyết triệt để vấn đề này, đề tài áp dụng hàm suy hao dị thể (Asymmetric Loss - ASL). Thay vì đối xử bình đẳng với mọi nhãn bệnh, ASL hoạt động dựa trên cơ chế phân tách trọng số. Công thức tổng quát của hàm ASL cho một mẫu dữ liệu đa nhãn được biểu diễn như sau:

$$L_{AS} = -\sum_{i=1}^{K} (y_i L_+ + (1 - y_i) L_-)$$

Trong đó, L_+ tập trung xử lý các mẫu dương tính (Positive - có bệnh) và L_- xử lý các mẫu âm tính (Negative - không mắc bệnh đó), được định nghĩa chi tiết:

$$L_+ = (1 - p_i)^{\gamma_+} \log(p_i)$$

$$L_- = (p_i^{(m)})^{\gamma_-} \log(1 - p_i^{(m)})$$

Thuật toán này định hướng lại quá trình học của mạng nơ-ron thông qua hai cơ chế cốt lõi:

- Phóng đại mức phạt ($\gamma_- > \gamma_+$): Phạt cực nặng (theo hàm mũ) các ca bệnh hiếm bị đoán sai (âm tính giả) và giảm nhẹ trọng số của các ca lành tính dễ đoán.
- Dịch chuyển xác suất (Margin m): Áp dụng lề m để loại bỏ hoàn toàn gradient của các mẫu âm tính có xác suất quá thấp, giúp mô hình không bị "áp đảo" bởi dữ liệu của nhóm bệnh phổ biến.

Nhờ sự tối ưu bất đối xứng này, mô hình MedAI Dermatology đạt Độ nhạy (Recall) rất cao đối với các bệnh lý nguy hiểm, đáp ứng chính xác tiêu chí sống còn trong chẩn đoán lâm sàng: "Thà bắt nhầm còn hơn bỏ sót".

2.2.6. Trực quan hóa và Giải thích (Explainable AI) với Grad-CAM

Việc ứng dụng Trí tuệ Nhân tạo trong y khoa thường vấp phải rào cản lớn mang tên "Hộp đen" (Black-box), do các mô hình học sâu truyền thống chỉ đưa ra kết quả mà không thể giải thích cơ sở luận lý cho các dự đoán đó. Để giải quyết triệt để bài toán minh bạch hóa, hệ thống MedAI Dermatology đã tích hợp thuật toán Grad-CAM (Gradient-weighted Class Activation Mapping).

Về cơ chế hoạt động, Grad-CAM tính toán đạo hàm (gradient) của nhãn bệnh lý được dự đoán đối với các bản đồ đặc trưng (Feature Maps) được trích xuất từ lớp tích chập (Convolution) cuối cùng của mạng EfficientNet-B4. Về mặt toán học, để xác định mức độ quan trọng của từng vùng không gian trên bức ảnh đối với một nhãn bệnh c cụ thể, trọng số α_k^c được tính toán như sau:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial Y^c}{\partial A_{ij}^k}$$

Sau khi thu được trọng số đại diện cho tầm quan trọng của từng bản đồ đặc trưng, bản đồ nhiệt tổng hợp (Heatmap) được sinh ra bằng tổ hợp tuyến tính, kết hợp với hàm kích hoạt ReLU nhằm chỉ giữ lại các điểm ảnh có tác động dương (làm tăng khả năng mắc bệnh c):

$$L_{Grad-CAM}^c = ReLU\left(\sum_k \alpha_k^c A^k\right)$$

Kết quả của quá trình này tạo ra một bản đồ nhiệt được chồng lấp (overlay) trực tiếp lên ảnh gốc, được diễn giải qua thang màu sắc trực quan:

- Vùng màu Đỏ/Cam: Biểu thị các điểm ảnh có mức độ đóng góp (Activation) cao nhất vào quyết định phân loại của AI, thường tương ứng chính xác với lõi khối u hoặc vùng da viêm nhiễm.
- Vùng màu Xanh lam: Tượng trưng cho vùng da lành lặn, nơi hệ số đóng góp vào kết quả chẩn đoán gần như bằng không.

Nhờ công nghệ Explainable AI này, quá trình suy luận phức tạp của máy tính đã được chuyển hóa thành một "bản đồ thị giác" trực quan. Nó cung cấp cho các chuyên gia da liễu một cơ sở tham chiếu đáng tin cậy để đối chiếu với kiến thức chuyên môn, từ đó đưa ra phác đồ điều trị chính xác và an toàn nhất cho bệnh nhân.

CHƯƠNG 3
PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH MEDAI DERMATOLOGY

3.1. Phân Tích Yêu Cầu Hệ Thống

3.1.1. Yêu Cầu Chức Năng

Hệ thống MedAI Dermatology được thiết kế với mục tiêu tự động hóa quy trình hỗ trợ chẩn đoán y khoa, đồng thời đảm bảo tính bảo mật và trải nghiệm người dùng tối ưu. Hệ thống bao gồm các yêu cầu chức năng cốt lõi sau:

- Quản lý Định danh & Phân quyền: Hệ thống cho phép người dùng (Bác sĩ, Bệnh nhân, Quản trị viên) đăng nhập, đăng ký và quản lý hồ sơ cá nhân. Phân quyền chặt chẽ các chức năng thao tác dữ liệu y tế dựa trên vai trò (Role-based Access Control).
- Tiếp nhận và Chẩn đoán AI: Upload hình ảnh da liễu từ thiết bị người dùng. Hệ thống tự động thực hiện tiền xử lý (DullRazor, YOLOv8) và gọi mô hình EfficientNet-B4 để đưa ra dự đoán phân loại 24 nhãn bệnh, kèm theo tỷ lệ tin cậy (Confidence Score).
- Trực quan hóa y khoa: Tự động sinh và hiển thị bản đồ nhiệt Grad-CAM đè lên ảnh gốc để giải thích vùng thương tổn trực quan cho bác sĩ.
- Thu thập phản hồi (Active Learning): Cho phép chuyên gia y tế đánh giá mức độ chính xác của AI đối với từng ca chẩn đoán (Đúng/Sai và ghi chú bệnh thực tế) để phục vụ việc tái huấn luyện mô hình.
- Thống kê & Quản trị Dashboard: Cung cấp biểu đồ thống kê dịch tễ học và đánh giá hiệu suất hoạt động thực tế của AI cho Quản trị viên hệ thống.

3.1.2. Yêu Cầu Phi Chức Năng

- Hiệu năng và Thời gian thực (Real-time): Thời gian phản hồi cho mỗi lượt tải ảnh và suy luận AI hoàn tất không được vượt quá 3 đến 5 giây để đảm bảo luồng công việc của bác sĩ không bị gián đoạn.
- Khả năng mở rộng (Scalability): Kiến trúc Backend bằng FastAPI và Cơ sở dữ liệu NoSQL (MongoDB) phải có khả năng xử lý bất đồng bộ, chịu tải tốt khi có nhiều luồng truy cập đồng thời.
- Tính bảo mật (Security): Mật khẩu người dùng được băm (hash) một chiều, phiên đăng nhập được bảo vệ bằng JWT Token. Dữ liệu hình ảnh y tế cá nhân phải được bảo mật tuyệt đối.

3.2. Mô Hình Hóa Hệ Thống

3.2.1. Sơ đồ Phân rã chức năng (BFD)

Sơ đồ phân rã chức năng thể hiện kiến trúc tổng thể của hệ thống MedAI Dermatology, được chia thành 4 phân hệ lõi nhằm đảm bảo tính độc lập nghiệp vụ (Separation of Concerns):

- Phân hệ Quản lý Định danh (1.0): Quản lý tài khoản và thiết lập cơ sở phân quyền RBAC (Role-Based Access Control) chặt chẽ.
- Phân hệ Lõi chẩn đoán AI (2.0): Là trái tim của hệ thống, bao gồm các cụm chức năng tiền xử lý, suy luận học sâu, đặc biệt bổ sung tính năng Phân tích cảnh báo rủi ro (Critical Warning) để phát hiện sớm các tín hiệu ung thư nằm ngoài Top 1 dự đoán.
- Phân hệ Nghiệp vụ Y tế (3.0): Quản lý hồ sơ bệnh án cá nhân, hỗ trợ các công cụ lọc theo mức rủi ro và xuất phiếu kết quả y khoa định dạng PDF phục vụ lưu trữ ngoại tuyến.
- Phân hệ Báo cáo Thống kê (4.0): Dành riêng cho cấp quản trị để theo dõi dịch tễ học và giám sát hiệu suất AI.

Hình 3.1 Sơ đồ Phân rã chức năng (BFD)

3.2.2. Sơ đồ Ca sử dụng (Use Case)

Sơ đồ Ca sử dụng mô tả chi tiết các luồng tương tác giữa các tác nhân (Actors) và hệ thống. Mô hình xác định rõ 4 nhóm tác nhân chính: Khách vãng lai, Bệnh nhân, Bác sĩ và Quản trị viên. Đặc biệt, luồng "Cung cấp Phản hồi Y khoa" được thiết kế dạng mở rộng (<<extend>>) từ chức năng chẩn đoán và xem lịch sử, thể hiện cơ chế vòng lặp phản hồi khép kín (Human-in-the-loop) để liên tục cải tiến mô hình.

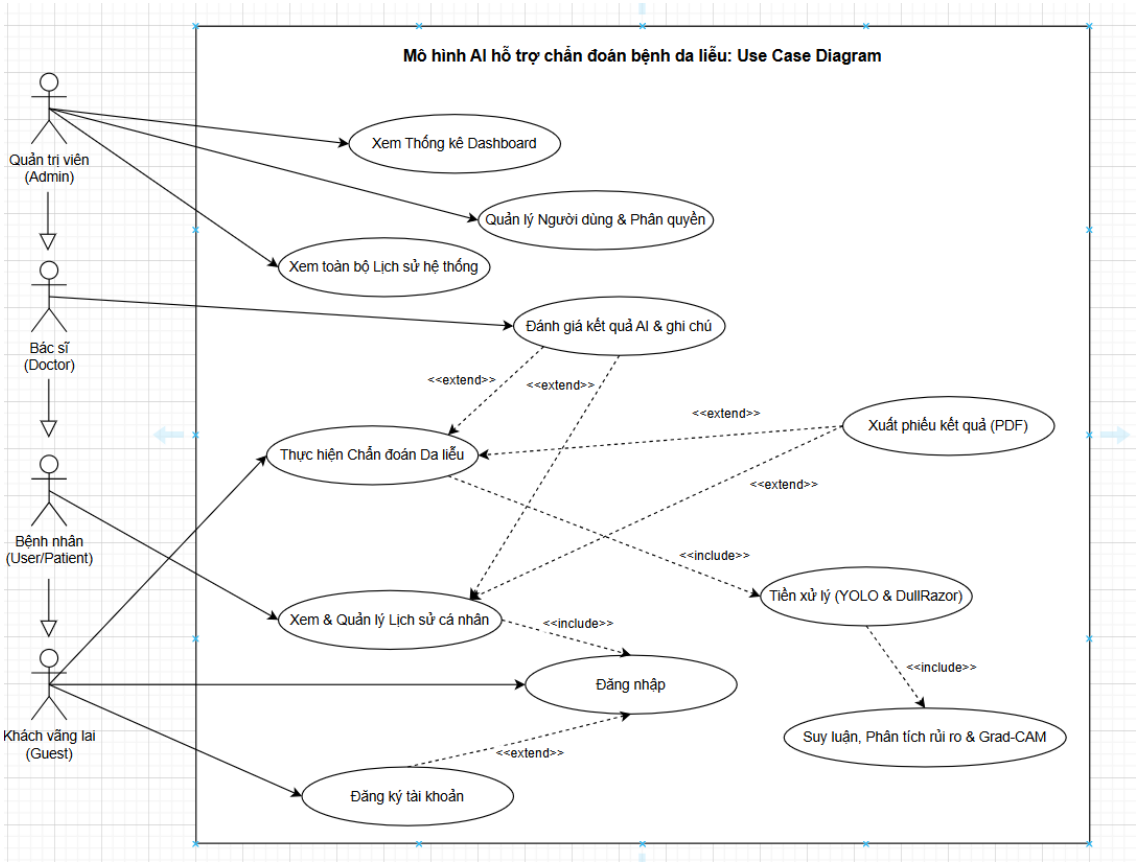

Hình 3.2 Sơ đồ Ca sử dụng (Use Case Diagram)

3.2.3. Sơ đồ Hoạt động (Activity Diagram)

Sơ đồ hoạt động dưới đây đặc tả chi tiết logic nghiệp vụ tuần tự kể từ khi người dùng tải ảnh lên. Sơ đồ đã làm rõ các điểm nhấn kỹ thuật cốt lõi của hệ thống MedAI Dermatology:

- Tiền xử lý song song: Phân đoạn cắt nền (YOLOv8) và Tẩy nhiễu lông (DullRazor) được chạy độc lập trước khi đưa vào mạng EfficientNet để tối ưu thời gian.
- Hậu xử lý xác suất: Khác với các hệ thống phân loại nhị phân thông thường, mô hình xuất ra cấu trúc Softmax gồm Top-3 bệnh lý và độc lập kiểm tra ngưỡng cảnh báo rủi ro (Critical Warning > 20%).
- Logic phân quyền lưu trữ (RBAC): Sơ đồ thể hiện rõ nhánh kiểm tra bảo mật. Hệ thống chỉ thực hiện lưu trữ hồ sơ bệnh án vào cơ sở dữ liệu nếu người dùng đã đăng nhập, ngược lại khách vãng lai (Guest) sẽ không bị lưu vết dữ liệu.
- Luồng học tập tích cực (Active Learning): Nhánh rẽ cuối cùng dành riêng cho tài khoản Bác sĩ thực hiện lưu vết đánh giá (Đúng/Sai) xuống MongoDB nhằm phục vụ tái huấn luyện mô hình.

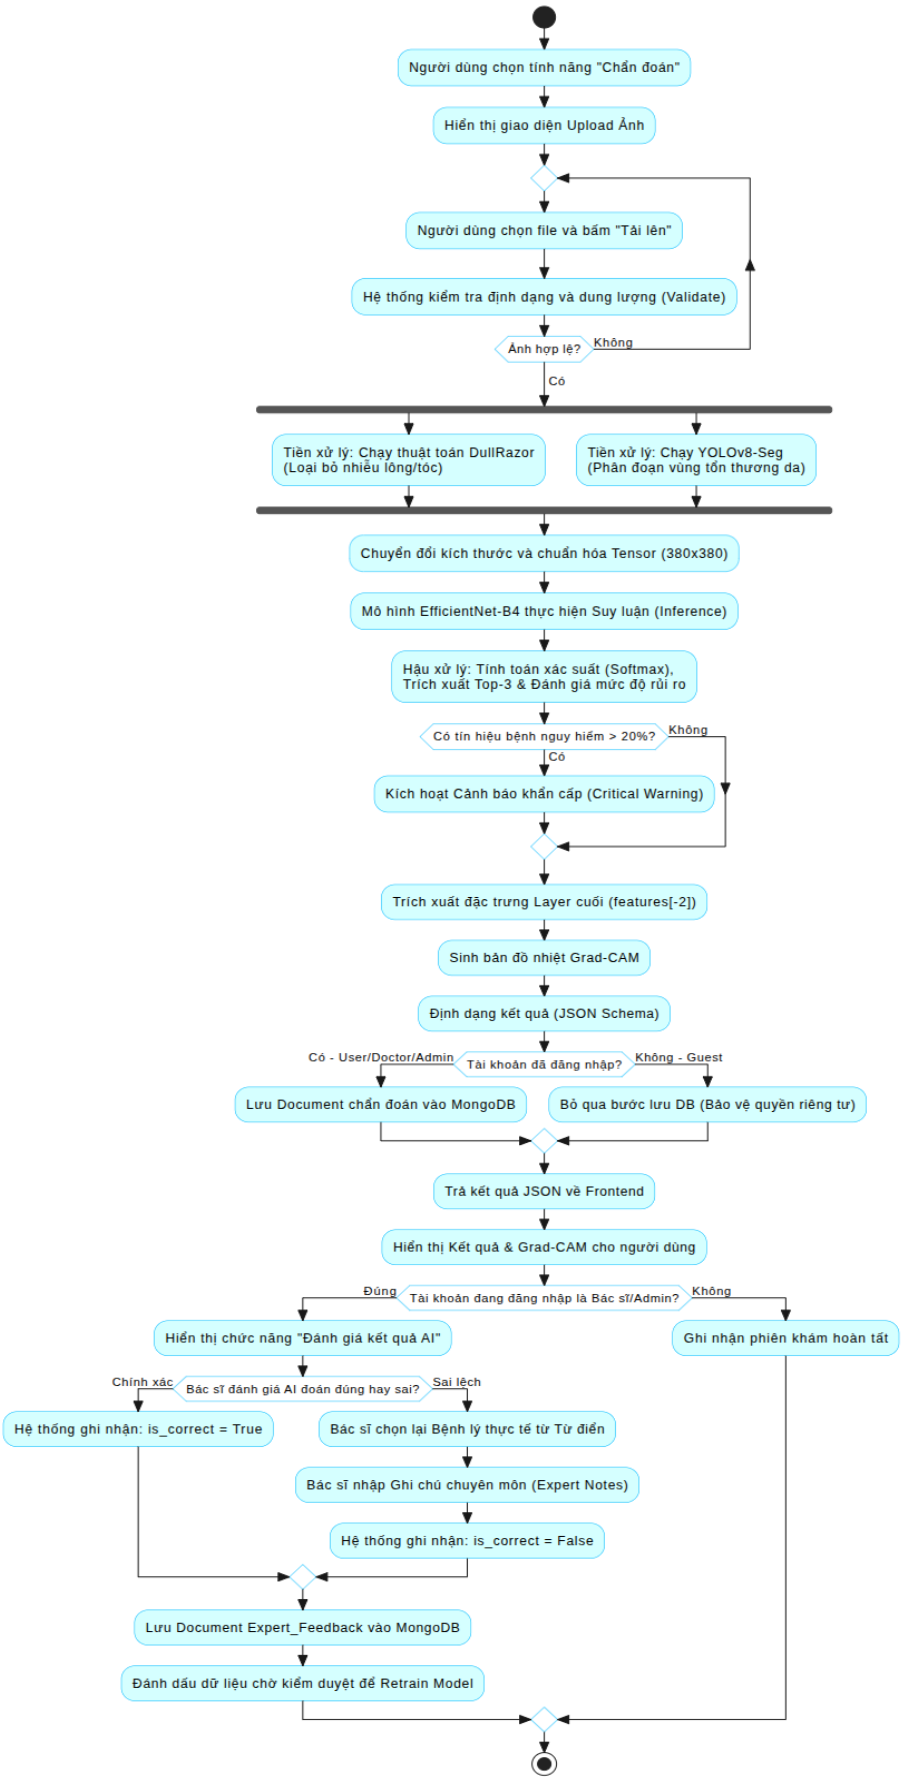

Hình 3.3 Sơ đồ Hoạt động quy trình chẩn đoán và thu thập phản hồi

3.2.4. Sơ đồ Tuần tự (Sequence Diagram)

Sơ đồ tuần tự mô tả luồng giao tiếp giữa các thành phần kiến trúc phân tán (Frontend, FastAPI, AI Engine và MongoDB) với các điểm nhấn sau:

- Giao tiếp API: Tuân thủ chuẩn RESTful, nhận ảnh đầu vào bằng multipart/form-data và trả kết quả qua cấu trúc JSON tinh gọn.
- Xử lý bất đồng bộ: Tầng FastAPI hoạt động như một Gateway, đẩy tác vụ tính toán nặng cho lõi PyTorch xử lý ngầm để không làm gián đoạn các truy cập khác.
- Tương tác NoSQL: Bỏ qua các lệnh SQL cứng nhắc, Backend ghi trực tiếp siêu dữ liệu y khoa vào MongoDB (dạng BSON) thông qua các lệnh lưu trữ tài liệu nguyên bản như insert_one.

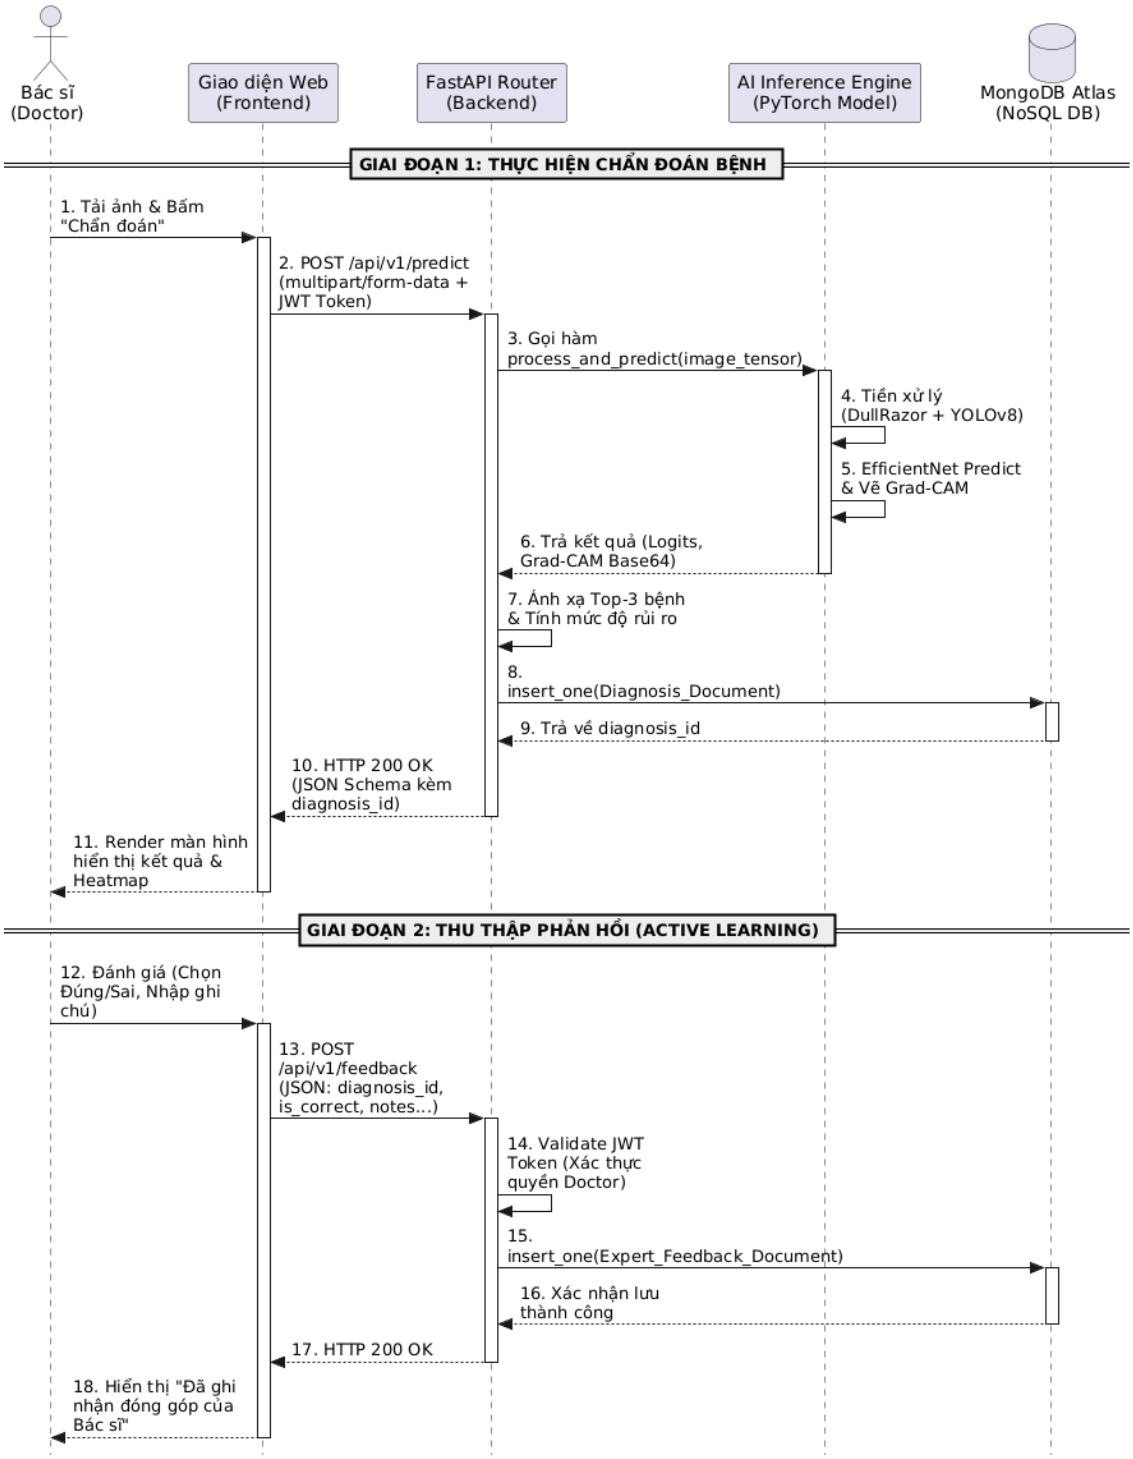

Hình 3.4 Sơ đồ Tuần tự giao tiếp các thành phần hệ thống

3.2.5. Luồng hậu xử lý và Cảnh báo rủi ro y khoa

Khác với các hệ thống phân loại thông thường chỉ lấy nhãn có xác suất cao nhất (Top-1), hệ thống MedAI Dermatology triển khai luồng hậu xử lý (Post-processing) chuyên biệt nhằm giảm thiểu rủi ro lâm sàng:

- Xuất top-3 dự đoán: Áp dụng hàm Softmax để xuất ra 3 bệnh lý có xác suất cao nhất, cung cấp bối cảnh so sánh cho bác sĩ.

- Phân nhóm mức độ rủi ro: Dựa vào bệnh lý dự đoán, hệ thống tự động ánh xạ sang 4 mức rủi ro: Thấp (Xanh), Trung bình (Vàng), Cao (Đỏ) và Đặc biệt nguy hiểm (Đỏ đậm), kèm theo khuyến nghị hành động tương ứng.
- Ngưỡng cảnh báo độc lập (Critical Warning): Hệ thống định nghĩa một danh sách các bệnh lý ác tính (như Melanoma, Ung thư tế bào đáy). Ngay cả khi các bệnh này không nằm ở vị trí Top 1, nhưng nếu xác suất dự đoán vượt qua ngưỡng cấu hình (mặc định > 20%), hệ thống vẫn sẽ kích hoạt cảnh báo nguy hiểm độc lập. Cơ chế này đảm bảo bác sĩ không bỏ sót bất kỳ tín hiệu nguy hiểm nào.
- Cơ chế dự phòng (Fallback): Trong trường hợp luồng tiền xử lý YOLOv8 thất bại hoặc không khả dụng, hệ thống tự động chuyển đổi sang cơ chế dự phòng (Resize-only kèm Padding) để đảm bảo trải nghiệm chẩn đoán không bị gián đoạn (Downtime).

3.3. Thiết Kế Cơ Sở Dữ Liệu

3.3.1. Sơ đồ Thực thể kết hợp (ERD - Mức logic)

Mặc dù hệ thống được triển khai vật lý trên nền tảng MongoDB (NoSQL) để tối ưu hóa việc lưu trữ các siêu dữ liệu AI phức tạp (định dạng BSON/JSON), mô hình dữ liệu mức logic (Logical Data Model) vẫn được thiết kế chuẩn hóa nhằm thể hiện rõ ràng các ranh giới nghiệp vụ. Để đảm bảo tính tinh gọn và hiệu năng truy xuất cao, cơ sở dữ liệu của hệ thống được thiết kế xoay quanh 4 thực thể cốt lõi.

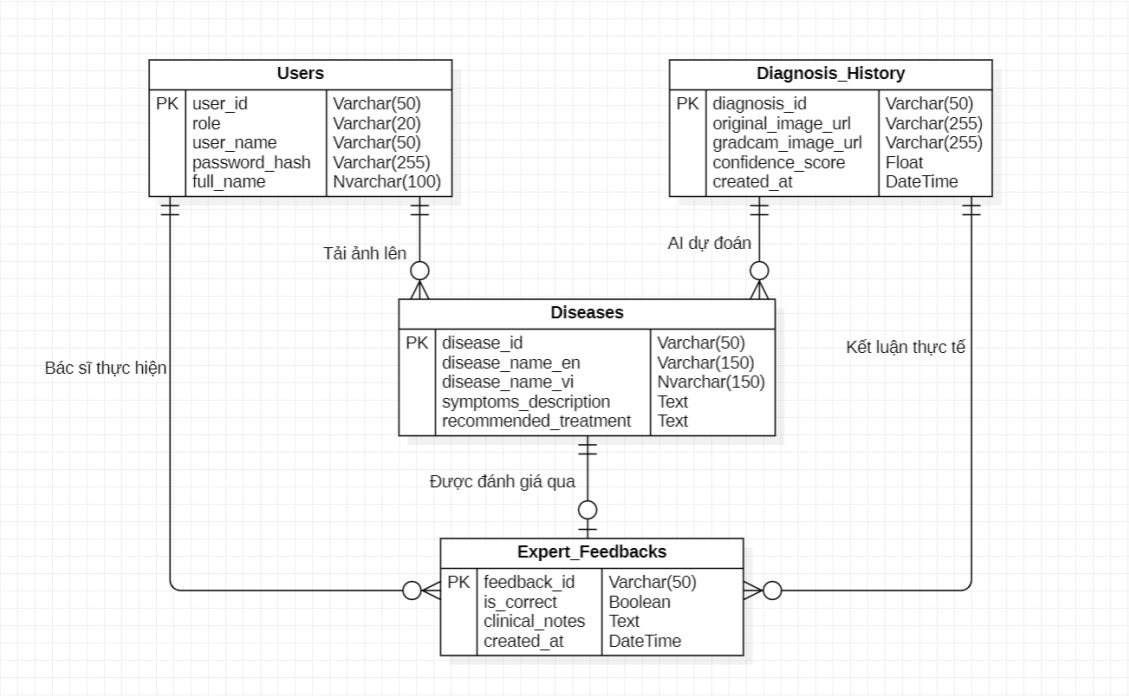

Hình 3.5 Sơ đồ Thực thể Kết hợp (ERD) mức logic

3.3.2. Đặc tả chi tiết các bảng dữ liệu

- Bảng Users

Thuộc tính	Diễn giải	Kiểu dữ liệu	Khóa
user_id	Mã định danh tài khoản	Varchar(50)	Khóa chính
role	Vai trò (Admin / Doctor / Patient)	Varchar(20)	
username	Tên đăng nhập	Varchar(50)	
password_hash	Mật khẩu (đã mã hóa)	Varchar(255)	
full_name	Họ và tên đầy đủ	Nvarchar(100)	

Bảng 3.1 Bảng Users

- Bảng Diseases

Thuộc tính	Diễn giải	Kiểu dữ liệu	Khóa
disease_id	Mã định danh bệnh lý	Varchar(50)	Khóa chính
disease_name_en	Tên bệnh (Tiếng Anh)	Varchar(150)	
disease_name_vi	Tên bệnh (Tiếng Việt)	Nvarchar(150)	
symptoms_description	Mô tả triệu chứng lâm sàng	Text	
recommended_treatment	Khuyến nghị hướng điều trị	Text	

Bảng 3.2 Bảng Diseases

- Bảng Diagnosis_History

Thuộc tính	Diễn giải	Kiểu dữ liệu	Khóa
diagnosis_id	Mã phiên chẩn đoán	Varchar(50)	Khóa chính
user_id	Mã tài khoản (Người tải ảnh lên)	Varchar(50)	Khóa phụ
predicted_disease_id	Mã bệnh AI dự đoán xác suất cao nhất	Varchar(50)	Khóa phụ
original_image_url	Đường dẫn lưu ảnh gốc tải lên	Varchar(255)	
gradcam_image_url	Đường dẫn lưu bản đồ nhiệt Grad-CAM	Varchar(255)	
confidence_score	Tỷ lệ % tự tin của mô hình AI	Float	
created_at	Dấu thời gian hệ thống xử lý	Datetime	

Bảng 3.3 Bảng Diagnosis_History

- Bảng Expert_Feedbacks

Thuộc tính	Diễn giải	Kiểu dữ liệu	Khóa
feedback_id	Mã định danh lượt đánh giá	Varchar(50)	Khóa chính
diagnosis_id	Mã phiên chẩn đoán được đánh giá	Varchar(50)	Khóa phụ
user_id	Mã tài khoản (Bác sĩ thực hiện đánh giá)	Varchar(50)	Khóa phụ
actual_disease_id	Mã bệnh thực tế (nếu AI đoán sai)	Varchar(50)	Khóa phụ
is_correct	Bác sĩ đánh giá AI đoán Đúng hay Sai	Boolean	
clinical_notes	Ghi chú chuyên môn của bác sĩ	Text	
created_at	Thời gian gửi đánh giá	Datetime	

Bảng 3.4 Bảng Expert_Feedbacks

3.4. Kiến trúc triển khai phân tán (Decoupled Architecture)

Hệ thống được thiết kế theo kiến trúc phân tán, tách biệt hoàn toàn giữa giao diện tương tác và lõi xử lý trí tuệ nhân tạo. Giải pháp này giúp tối ưu hóa hiệu năng, chịu tải tốt và dễ dàng mở rộng trên môi trường thực tế (Cloud):

- Triển khai máy chủ Web (Frontend) trên VPS iNet qua 1Panel: Giao diện ứng dụng người dùng (Web Application) được lưu trữ và vận hành trên máy chủ ảo (VPS) của nhà cung cấp iNet, được quản trị thông qua nền tảng 1Panel. Việc đặt Frontend tại máy chủ nội địa giúp tối ưu hóa tốc độ tải trang gốc, quản lý tên miền (Domain), chứng chỉ bảo mật (SSL) và cấu hình Nginx dễ dàng, mang lại trải nghiệm mượt mà và độ trễ thấp cho người dùng cuối tại Việt Nam.
- Triển khai lõi Backend và AI trên Hugging Face Spaces: Toàn bộ khối lượng tính toán nặng bao gồm API Server (FastAPI), các mô hình học sâu

(EfficientNet-B4, YOLOv8) và luồng tiền xử lý ảnh (DullRazor) được đóng gói Docker và triển khai độc lập trên nền tảng đám mây Hugging Face Spaces. Việc tận dụng môi trường máy chủ chuyên dụng cho Machine Learning này giúp giải quyết triệt để bài toán tài nguyên phần cứng (RAM/CPU), đảm bảo quá trình suy luận AI diễn ra trơn tru mà không làm treo máy chủ Web.

- Cơ chế giao tiếp (API Integration): Hệ thống hoạt động theo mô hình Client-Server. Giao diện Frontend tại iNet sẽ tiếp nhận ảnh từ người dùng và đóng vai trò là Client, gửi dữ liệu qua các luồng gọi RESTful API bảo mật đến máy chủ Hugging Face. Sau khi hoàn tất phân tích, Backend trả kết quả JSON về để Frontend hiển thị, tạo thành một chu trình xử lý khép kín và an toàn.

CHƯƠNG 4
KẾT QUẢ THỰC NGHIỆM VÀ GIAO DIỆN HỆ THỐNG

4.1. Xây dựng và Chuẩn bị Bộ dữ liệu thực nghiệm

4.1.1. Các nguồn dữ liệu thành phần

Để đảm bảo mô hình AI có khả năng nhận diện đa dạng các bệnh lý và hoạt động tốt trong điều kiện ánh sáng thực tế, bộ dữ liệu huấn luyện của hệ thống MedAI Dermatology không sử dụng một nguồn đơn lẻ mà được tổng hợp và chắt lọc từ 3 bộ dữ liệu y khoa uy tín nhất hiện nay:

- ISIC 2019 (International Skin Imaging Collaboration): Đây là bộ dữ liệu chuẩn mực nhất thế giới về hình ảnh soi da (Dermoscopy). ISIC cung cấp các mẫu ảnh chất lượng cao, độ phân giải lớn, tập trung chủ yếu vào các tổn thương sắc tố và ung thư da ác tính (như Melanoma, Basal Cell Carcinoma).
- DermNet: Khác với ISIC, DermNet là bộ sưu tập khổng lồ các hình ảnh lâm sàng (Clinical images) chụp bằng máy ảnh thông thường. Bộ dữ liệu này bổ sung hàng loạt các nhãn bệnh da liễu phổ biến mà ISIC còn thiếu như: mụn trứng cá (Acne), chàm (Eczema), vảy nến (Psoriasis) và các bệnh lý do nấm, virus.
- PAD-UFES-20: Đây là bộ dữ liệu chứa các hình ảnh tổn thương da được chụp trực tiếp từ điện thoại thông minh (Smartphone) đi kèm với siêu dữ liệu lâm sàng của bệnh nhân. Việc bổ sung PAD-UFES-20 giúp mô hình làm quen với các điều kiện nhiễu thực tế (ánh sáng kém, góc chụp lệch, mờ nhòe), sát với hành vi sử dụng của người dùng cuối.

4.1.2. Phương pháp tích hợp và đồng bộ hóa dữ liệu

Việc gộp 3 bộ dữ liệu độc lập này đòi hỏi một quy trình tiền xử lý và đồng bộ hóa khắt khe để tránh xung đột mô hình. Quá trình này được thực hiện qua các bước:

- Ánh xạ và Chuẩn hóa nhãn (Label Mapping): Các thuật ngữ y khoa giữa 3 bộ dữ liệu đôi khi khác nhau (ví dụ: Melanocytic Nevi và Nevus). Đề tài đã tiến hành rà soát y văn, gom nhóm các nhãn bệnh trùng lặp và loại bỏ các nhãn có quá ít dữ liệu. Kết quả cuối cùng ánh xạ thành 24 nhãn bệnh lý (Classes) phân biệt rõ ràng.
- Làm sạch dữ liệu (Data Cleaning): Các hình ảnh bị hỏng (corrupted), sai định dạng, hoặc có độ phân giải quá thấp (< 100x100 pixel) đều được thuật toán tự động lọc bỏ.

- Phân chia tập dữ liệu (Stratified Splitting): Dữ liệu được chia theo tỷ lệ tiêu chuẩn 80% (Huấn luyện - Train), 10% (Xác thực - Validation) và 10% (Kiểm thử - Test). Thuật toán phân chia phân tầng (Stratified) được áp dụng để đảm bảo tỷ lệ phân phối của 24 bệnh lý luôn đồng đều giữa các tập.

4.1.3. Đặc tả kết quả bộ dữ liệu tổng hợp

Sau quá trình tích hợp, bộ dữ liệu MedAI Dermatology mang hai đặc điểm cốt lõi đóng vai trò quyết định đến hiệu năng của hệ thống:

- Tính đa phương thức hình ảnh: Việc chứa cả ảnh soi da vi mô (Dermoscopy) lẫn ảnh chụp bề mặt vĩ mô (Clinical/Smartphone photos) giúp mạng nơ-ron EfficientNet-B4 học được đặc trưng bệnh lý từ nhiều góc độ và điều kiện thiết bị khác nhau.
- Đặc tính phân phối đuôi dài (Long-tail Distribution): Hệ thống phản ánh chân thực tỷ lệ mắc bệnh ngoài đời thực. Nhóm bệnh lành tính (Mụn, nấm, viêm da) chiếm số lượng mẫu rất lớn (vài nghìn ảnh/nhãn), trong khi nhóm bệnh hiếm và nguy hiểm (như Ung thư hắc tố Melanoma) có số lượng hạn chế hơn. Đây chính là cơ sở thực tiễn bắt buộc hệ thống phải áp dụng cấu trúc Asymmetric Loss (Hàm suy hao dị thể) ở quá trình huấn luyện nhằm ngăn chặn tình trạng thiên lệch nhãn (Bias).

4.2. So sánh hệ thống với các công trình liên quan (SOTA)

Để đánh giá khách quan tính thực tiễn và sự cải tiến của giải pháp, kết quả của mô hình MedAI Dermatology được đối chiếu với các công trình nghiên cứu nổi bật gần đây trong cùng lĩnh vực.

Tiêu chí so sánh	Nguyễn Tú Anh (2024)	Harshith S. (2025)	Jayanth Mohan (2025)	MedAI Dermatology (Đề xuất)
Kiến trúc mô hình	CNN truyền thống	YOLOv8 + EfficientNet-B0	Transformer-based	YOLOv8-Seg + EfficientNet-B4
Quy mô phân loại	7 lớp bệnh (ISIC-2018)	Các bệnh cơ bản	Đa nhãn	24 lớp bệnh (ISIC, DermNet, PAD-UFES-20)
Xử lý nhiễu bề mặt	Không đề cập	Cắt nền bằng YOLO	Tiền xử lý cơ bản	Tẩy lông (DullRazor) + Cắt nền (YOLO)
Xử lý mất cân bằng dữ liệu	Augmentation cơ bản	Sử dụng trọng số lớp (Class Weights)	Kỹ thuật lấy mẫu (Sampling)	Hàm mất mát bất đối xứng (Asymmetric Loss)
Trực quan hóa (XAI)	Phân đoạn vùng	Không nổi bật	Có tích hợp XAI	Bản đồ nhiệt Grad-CAM
Hiệu năng nổi bật	Tối ưu trên tập ISIC-2018	Tốc độ cao (Real-time)	Khai thác đặc trưng toàn cục	Accuracy: 88.5%F1-Macro: 0.880

Bảng 4.1 Bảng so sánh hiệu năng và tính năng với các nghiên cứu liên quan

4.3. Quá trình tinh chỉnh và Tiến hóa của Mô hình

Để đạt được các chỉ số vượt trội so với các nghiên cứu trên, lõi AI của hệ thống đã phải trải qua 3 giai đoạn tối ưu hóa khắt khe:

- V1.0 (Baseline): Sử dụng EfficientNet-B3 (TensorFlow) trên 8 lớp bệnh. Do nhiễu phông nền và mất cân bằng dữ liệu, độ chính xác (Accuracy) chỉ đạt ~73%.

- V2.0 & V2.1: Chuyển sang PyTorch, nâng cấp lên mạng EfficientNet-B4. Tích hợp luồng tiền xử lý YOLOv8 (cắt nền) và DullRazor (tẩy lông), mở rộng nhận diện 24 lớp bệnh. Độ chính xác tăng lên 86.2%.
- V3.0 (Hiện tại): Tích hợp hàm suy hao dị thể (Asymmetric Loss) để giải quyết triệt để việc bỏ lọt bệnh hiếm. Mô hình đạt đỉnh hiệu năng với Accuracy 88.5% và F1-Macro 0.880.

Sự bứt phá hiệu năng qua từng phiên bản được thể hiện trực quan qua biểu đồ dưới đây:

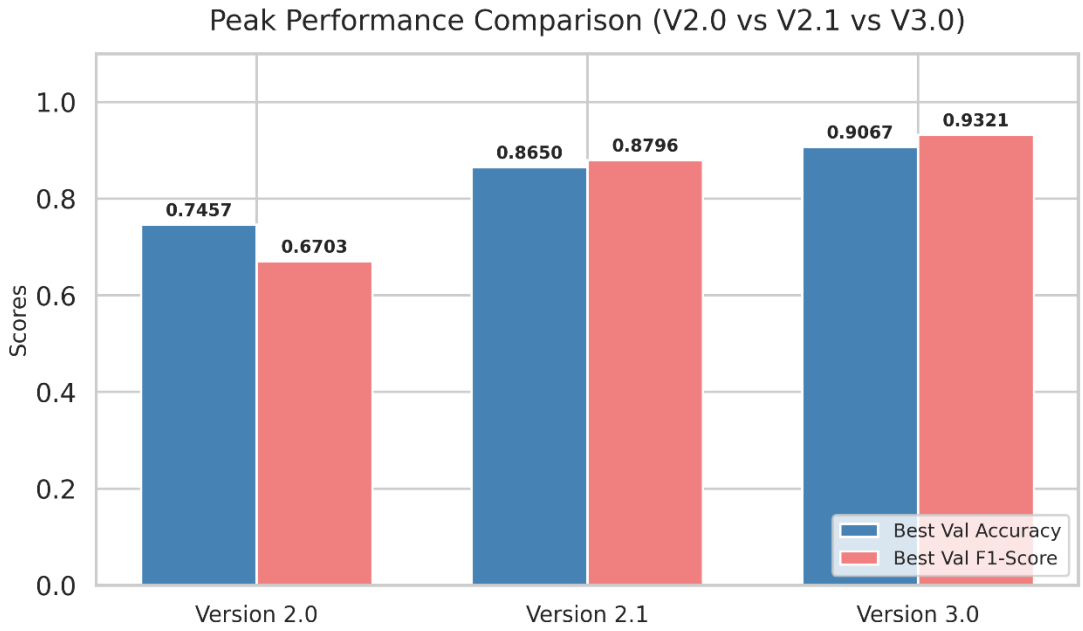

Hình 4.1 Biểu đồ thể hiện sự cải thiện độ chính xác qua các phiên bản mô hình

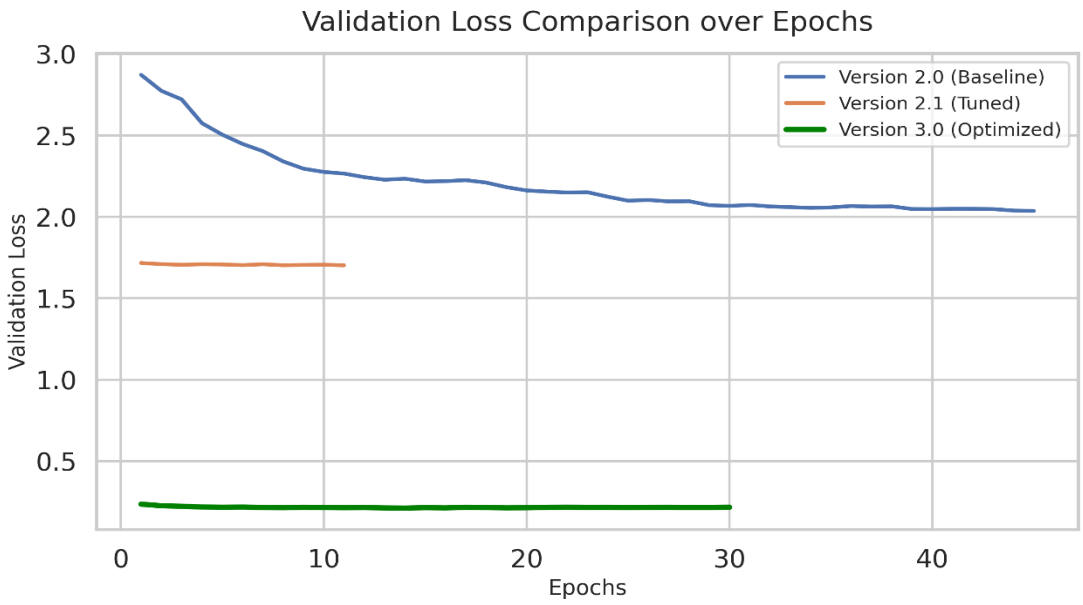

Hình 4.2 Biểu đồ đường cong hàm mất mát (Validation Loss) qua các phiên bản mô hình.

Sự hội tụ của hàm mất mát cho thấy phiên bản V3.0 (đường màu xanh lá) đã duy trì được mức Loss cực thấp và ổn định nhất, khắc phục hoàn toàn sự dao động của các phiên bản tiền nhiệm.

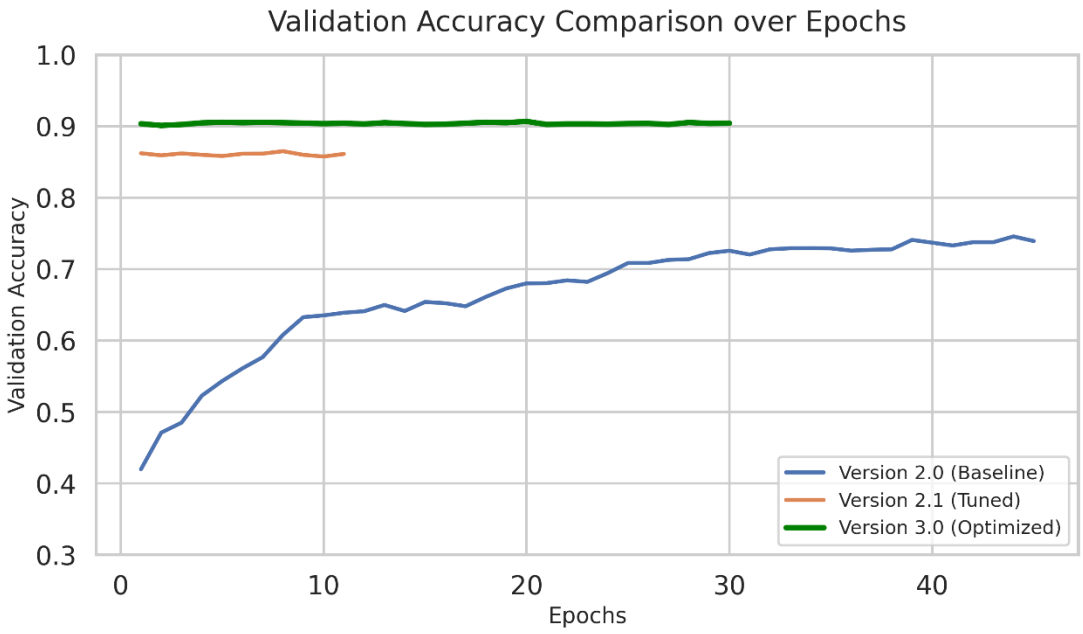

Hình 4.3 Biểu đồ độ chính xác kiểm định (Validation Accuracy) qua các phiên bản mô hình.

Đường cong Accuracy khẳng định mô hình V3.0 đạt và duy trì được độ chính xác rất cao (~88.5%) xuyên suốt quá trình huấn luyện mà không có dấu hiệu suy giảm.

4.4. Phân tích qua các chỉ số trực quan

Để đánh giá khách quan sức mạnh của lõi AI, quá trình thực nghiệm đã trích xuất các biểu đồ đo lường chuyên sâu và ma trận đánh giá hiệu năng mô hình.

4.4.1. Đánh giá qua Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn giúp trực quan hóa khả năng phân loại chéo giữa 24 nhãn bệnh. Kết quả biểu đồ cho thấy mô hình phân loại cực kỳ chính xác các nhóm bệnh lành tính phổ biến. Đặc biệt, các nhóm ung thư nguy hiểm (như Melanoma, Basal Cell Carcinoma) có tỷ lệ nhận diện đúng (Recall) rất cao, đáp ứng tốt nguyên tắc "không bỏ sót" (giảm thiểu âm tính giả) trong chẩn đoán y khoa.

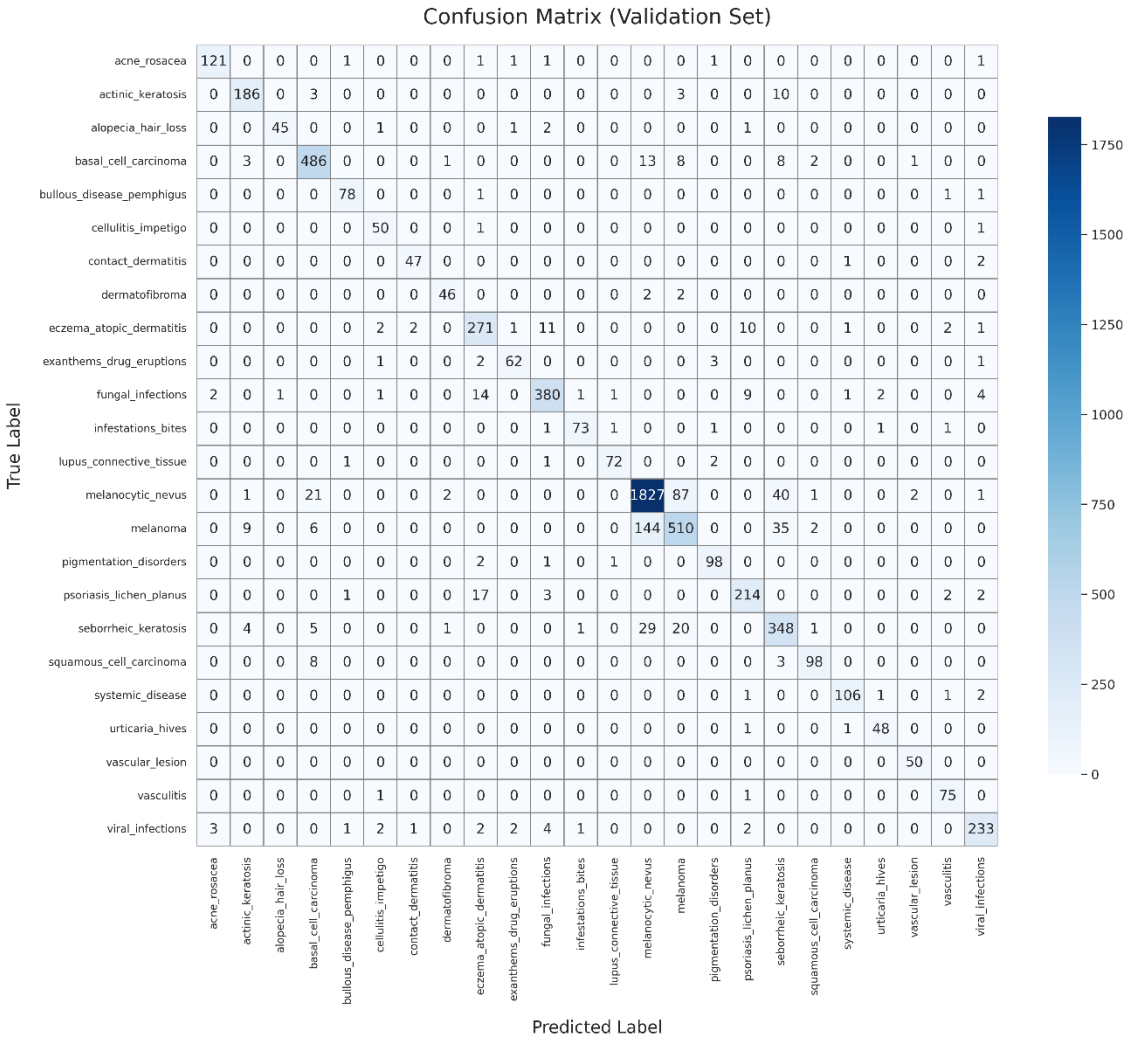

Hình 4.4 Ma trận nhầm lẫn (Confusion Matrix) đánh giá trên tập kiểm thử

4.4.2. Đánh giá qua Đường cong học tập (Learning Curves)

Đường cong học tập cho thấy mô hình hội tụ rất ổn định và không bị quá khớp (Overfitting), thể hiện qua việc Train Loss và Val Loss giảm đều, bám sát nhau. Đặc biệt, chỉ số Validation Macro F1 đạt đỉnh ấn tượng tại kỷ nguyên (Epoch) thứ 20. Điều này minh chứng cho sự thành công của hàm Asymmetric Loss khi mô hình vừa nhận diện tốt các nhóm bệnh phổ biến, vừa duy trì độ nhạy (Recall) cực kỳ cao đối với các ca bệnh hiếm và nguy hiểm.

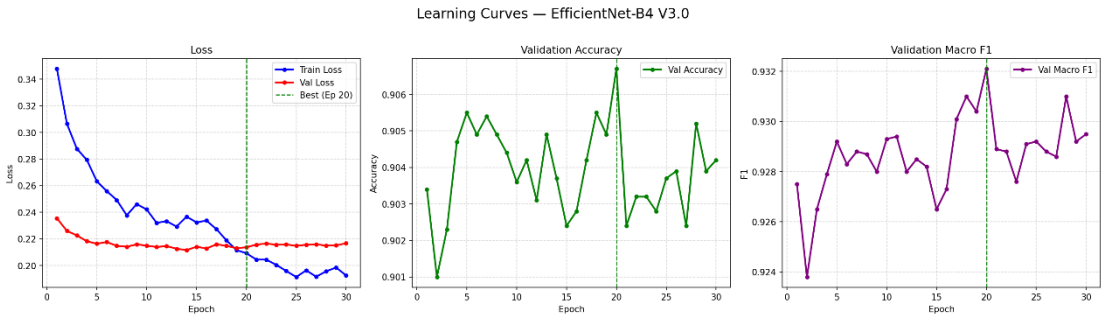

Hình 4.5 Sơ đồ đường cong học tập (Learning Curves) của mô hình EfficientNet-B4 V3.0.

4.4.3. Minh bạch hóa dự đoán với bản đồ nhiệt Grad-CAM

Để xóa bỏ rào cản "hộp đen" của AI, hệ thống áp dụng thuật toán Grad-CAM. Qua thực nghiệm trực quan trên các ca bệnh thực tế, vùng màu đỏ trên bản đồ nhiệt luôn bám sát vào các đặc điểm bệnh học lõi (như viền nốt ruồi không đều, khu vực tế bào viêm nhiễm). Điều này chứng minh AI đã thực sự "học" các đặc trưng y khoa cốt lõi để ra quyết định thay vì đoán mò dựa trên các yếu tố nhiễu của phông nền.

Hình 4.6 Trực quan hóa vùng tổn thương qua Grad-CAM

4.5. Giao Diện Hệ Thống Thực Tế

4.5.1. Giao Diện Đăng Ký Tài Khoản

Giao diện đăng ký được thiết kế tối giản dưới dạng Modal (hộp thoại nổi), cho phép người dùng thao tác nhanh chóng mà không bị chuyển hướng sang một trang web khác, giúp giữ nguyên luồng trải nghiệm. Việc yêu cầu tạo tài khoản nhằm mục đích định danh người dùng, tạo cơ sở bảo mật để hệ thống lưu trữ và theo dõi xuyên suốt lịch sử bệnh lý cho từng cá nhân.

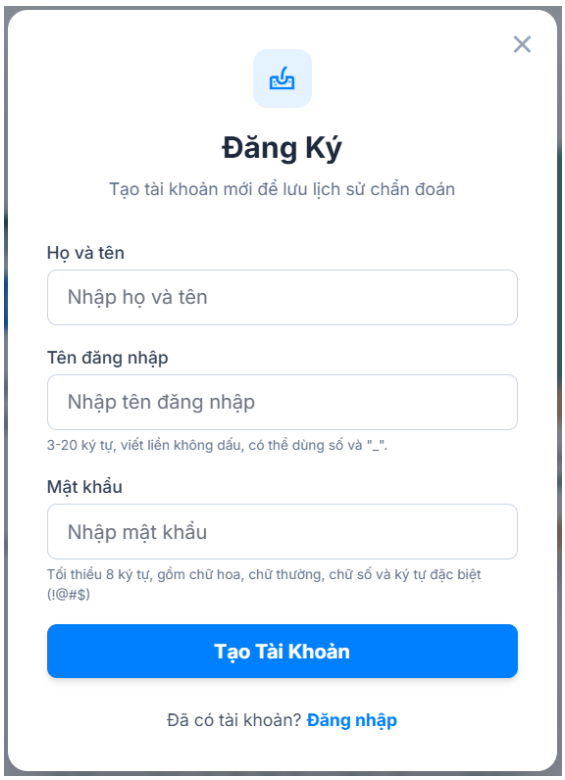

Hình 4.7 Giao diện đăng ký tài khoản

4.5.2. Giao Diện Đăng Nhập

Tương tự như chức năng đăng ký, giao diện đăng nhập cũng tuân thủ nguyên tắc thiết kế phẳng (Flat Design) và hiển thị trực quan. Chức năng này đóng vai trò như một chốt chặn bảo mật để xác thực danh tính. Dựa vào thông tin tài khoản đăng nhập, hệ thống sẽ tự động phân quyền (Bệnh nhân, Bác sĩ hoặc Quản trị viên) nhằm hiển thị đúng lịch sử khám cá nhân, đồng thời mở khóa các tính năng đánh giá chuyên môn tương ứng với vai trò của người dùng.

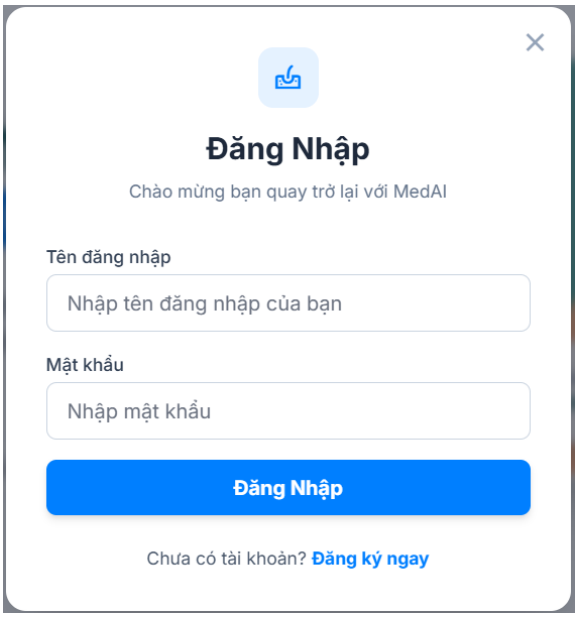

Hình 4.8 Giao diện đăng nhập

4.5.3. Giao Diện Trang Chủ

Trang chủ (Landing Page) được thiết kế theo phong cách phẳng (Flat Design) kết hợp tông màu xanh y tế nhằm tạo sự tin cậy. Giao diện làm nổi bật thông điệp về công nghệ AI cốt lõi và cung cấp nút điều hướng Call-to-action (Chẩn đoán ngay) đặt ở vị trí trung tâm, giúp người dùng nhanh chóng tiếp cận tính năng chính của phần mềm.

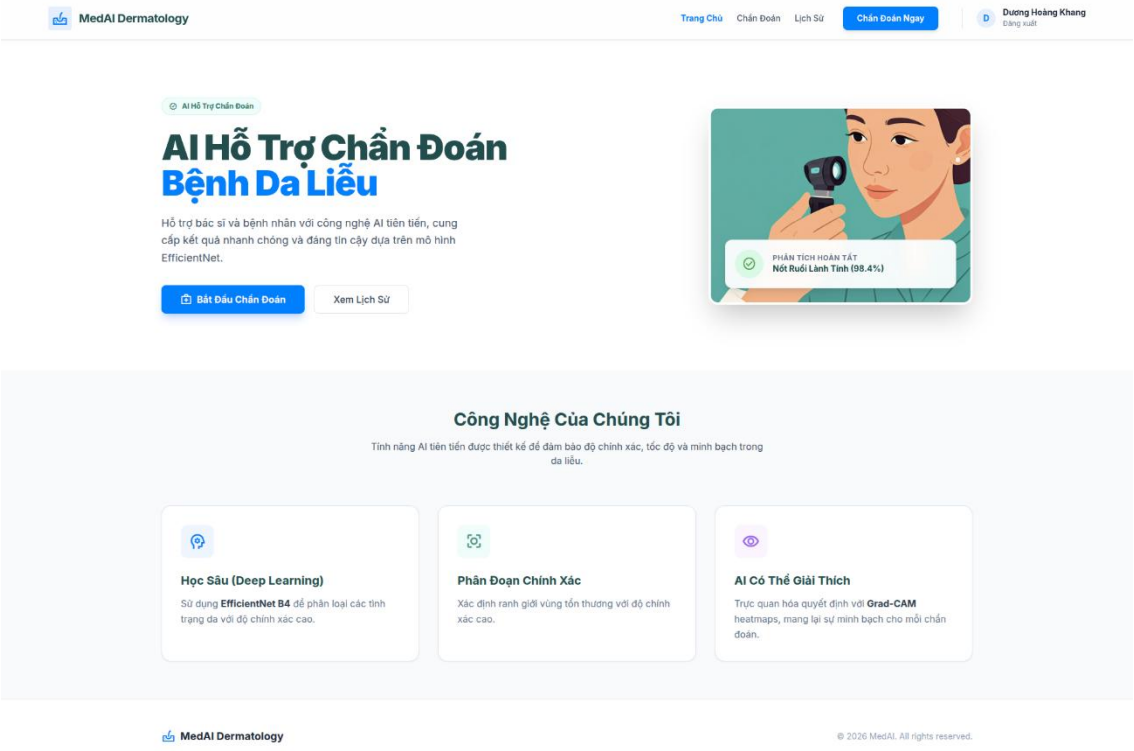

Hình 4.9 Giao diện trang chủ

4.5.4. Giao Diện Chẩn Đoán Bệnh

Khu vực tải ảnh phân tích được thiết kế với không gian rộng rãi, hỗ trợ cả thao tác kéo thả (Drag & Drop) tập tin và tính năng chụp ảnh trực tiếp từ Camera thiết bị. Giao diện cũng tích hợp danh sách các khuyến cáo trực quan (ánh sáng tốt, không bóng đổ) giúp người dùng cung cấp nguồn dữ liệu đầu vào chất lượng nhất cho mạng nơ-ron phân tích.

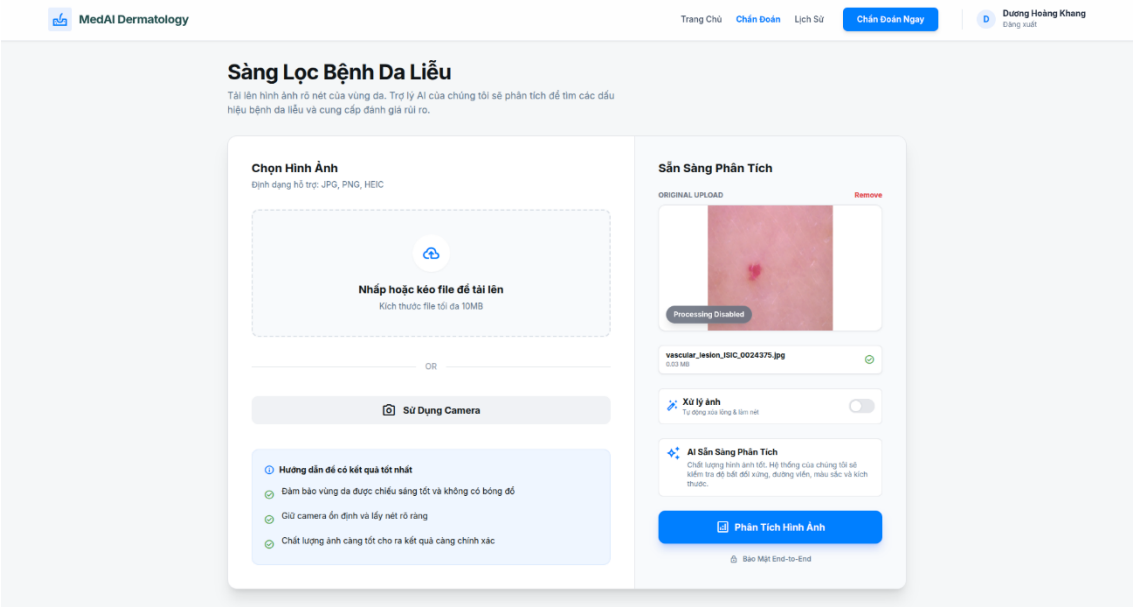

Hình 4.10 Giao diện chẩn đoán bệnh

4.5.5. Giao Diện Nhận Kết Quả Chẩn Đoán

Đây là giao diện đóng vai trò cốt lõi của hệ thống. Kết quả trả về không chỉ hiển thị tên bệnh lý dự đoán và độ tin cậy (Confidence Score), mà còn minh bạch hóa quyết định của AI bằng bản đồ nhiệt Grad-CAM đè lên ảnh gốc. Các mức độ rủi ro (Cao/Trung bình/Thấp) được cảnh báo bằng màu sắc nổi bật. Đặc biệt, nếu tài khoản đang đăng nhập là Bác sĩ, phía dưới cùng sẽ xuất hiện thêm khối chức năng "Đánh giá Chẩn đoán AI" để phục vụ việc thu thập phản hồi.

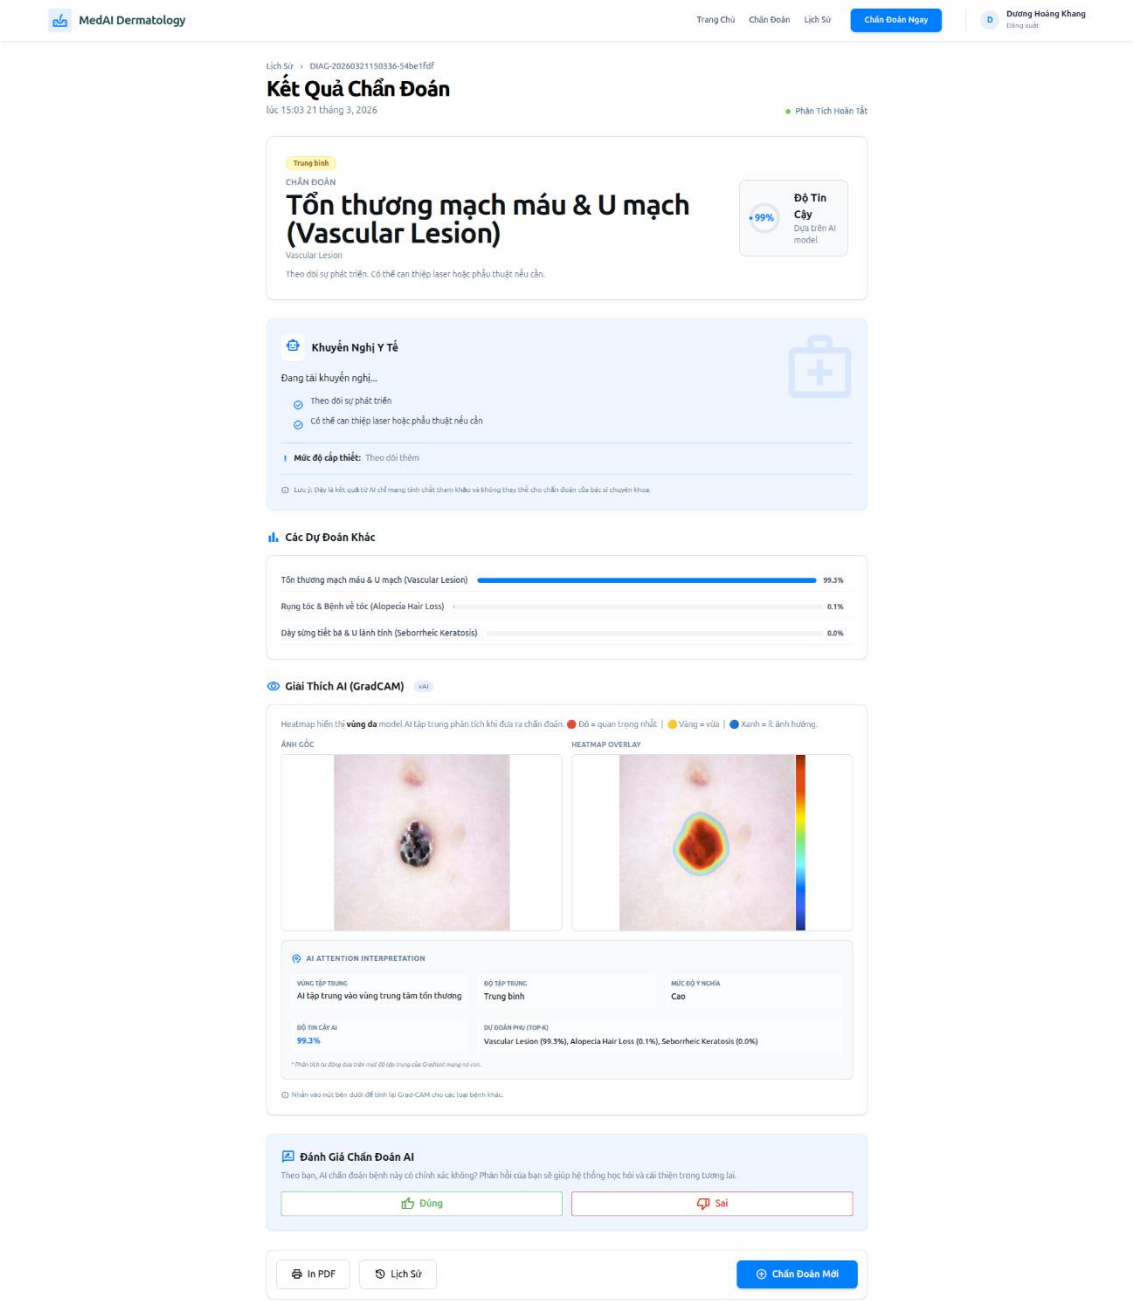

Hình 4.11 Giao diện nhận kết quả chẩn đoán

4.5.6. Giao Diện Xem Lịch Sử Chẩn Đoán

Giao diện Lịch sử chẩn đoán được hiển thị dưới dạng bảng dữ liệu (Data Grid) trực quan, hỗ trợ tìm kiếm theo mã phiên khám và lọc nhanh (Tags) theo mức độ rủi ro. Điểm nhấn của phân hệ này là cơ chế lưu trữ và hiển thị tuân thủ nghiêm ngặt logic phân quyền người dùng (Role-Based Access Control):

- Đối với Khách vãng lai (Guest): Người dùng không cần đăng nhập vẫn có thể sử dụng AI để phân tích ảnh, tuy nhiên hệ thống sẽ không lưu lại lịch sử chẩn đoán nhằm đảm bảo quyền riêng tư.
- Đối với Người dùng tiêu chuẩn (Bệnh nhân/Bác sĩ): Hệ thống chỉ lưu và hiển thị danh sách các phiên khám của chính tài khoản đó, giúp người bệnh dễ dàng theo dõi tiến triển của vùng da tổn thương qua từng thời kỳ.
- Đối với Quản trị viên (Admin): Tài khoản được phân quyền Admin có đặc quyền xem toàn bộ lịch sử chẩn đoán của tất cả người dùng trên hệ thống, phục vụ cho công tác quản lý, giám sát và trích xuất dữ liệu thống kê dịch tễ.

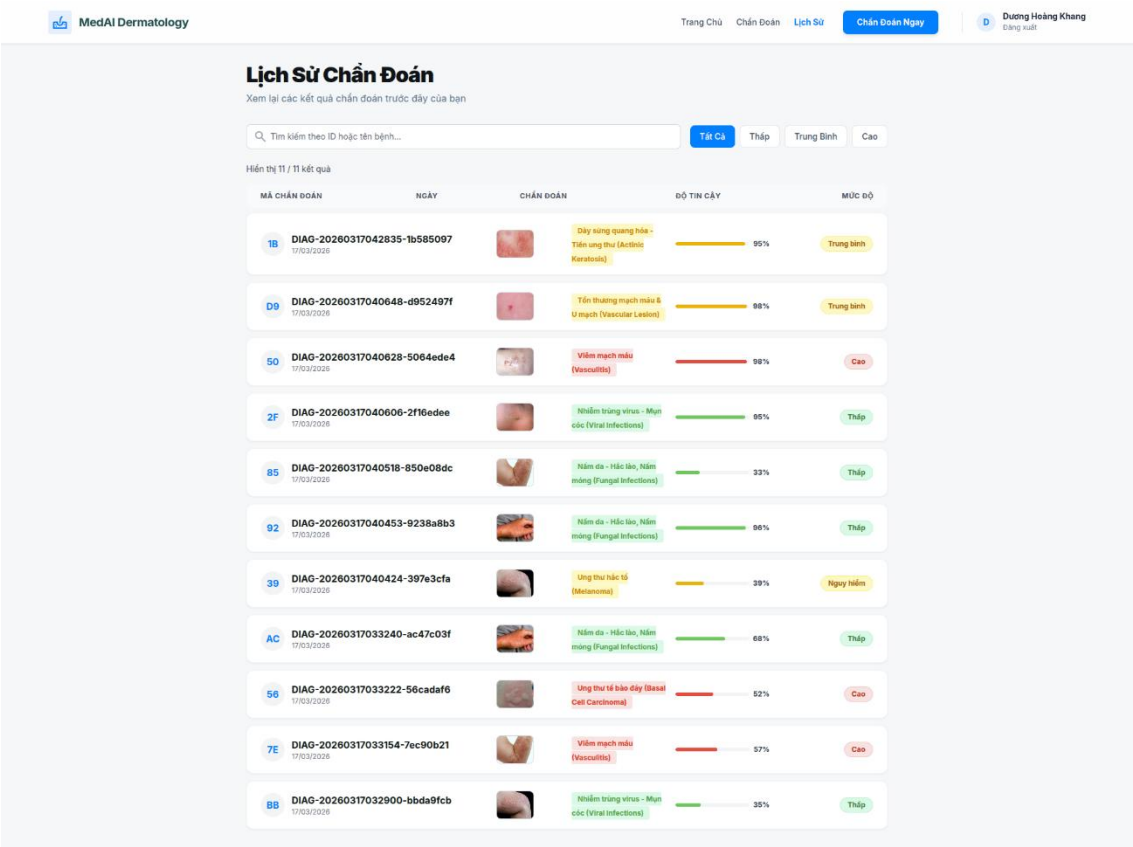

Hình 4.12 Giao diện xem lịch sử chẩn đoán

CHƯƠNG 5
KẾT LUẬN

5.1. Kết Quả Đạt Được

Sau quá trình nghiên cứu lý thuyết, phân tích thiết kế và tiến hành thực nghiệm, đồ án "Mô hình AI hỗ trợ chẩn đoán bệnh da liễu từ ảnh da MedAI Dermatology" đã hoàn thành tốt các mục tiêu đề ra ban đầu. Kết quả của đồ án được thể hiện qua hai khía cạnh cốt lõi:

Về mặt nghiên cứu và huấn luyện Trí tuệ Nhân tạo:

- Xây dựng thành công luồng tiền xử lý (Preprocessing Pipeline): Áp dụng hiệu quả thuật toán hình thái học DullRazor để loại bỏ nhiễu lông và mô hình YOLOv8-Segmentation để cắt bỏ phông nền, giúp mô hình phân loại tập trung 100% vào vùng da tổn thương.
- Tối ưu hóa mô hình học sâu: Huấn luyện thành công mạng nơ-ron tích chập EfficientNet-B4. Việc kết hợp với hàm suy hao dị thể Asymmetric Loss đã giải quyết được bài toán mất cân bằng dữ liệu y tế nghiêm trọng. Mô hình đạt hiệu suất ấn tượng với khả năng phân loại 24 nhóm bệnh lý da liễu, đạt độ chính xác tổng thể (Accuracy) xấp xỉ 88.5% và chỉ số F1-Macro đạt 0.880.
- Tích hợp công nghệ giải thích mô hình (Explainable AI): Cài đặt thành công thuật toán Grad-CAM, tự động sinh bản đồ nhiệt (Heatmap) chỉ ra vùng ra quyết định của AI, giúp xóa bỏ rào cản "hộp đen" và gia tăng độ tin cậy đối với các bác sĩ lâm sàng.

Về mặt phát triển hệ thống phần mềm:

- Triển khai kiến trúc hiện đại: Xây dựng hoàn chỉnh ứng dụng nền web (Web Application) với tầng Backend sử dụng FastAPI xử lý luồng bất đồng bộ, kết hợp hệ quản trị cơ sở dữ liệu phi quan hệ MongoDB giúp lưu trữ tối ưu các khối dữ liệu JSON/BSON phức tạp sinh ra từ AI.
- Hoàn thiện các tính năng nghiệp vụ: Hoạt động ổn định với các chức năng phân quyền người dùng (Role-Based), quản lý hồ sơ y tế, và tải ảnh chẩn đoán theo thời gian thực.
- Thiết lập vòng lặp MLOps: Xây dựng thành công chức năng "Đánh giá chuyên gia" (Expert Feedback), cho phép y bác sĩ đính chính kết quả của AI. Tính năng này tạo ra nguồn dữ liệu gán nhãn sạch (Clean Labels), đặt nền móng vững chắc cho việc học tập tích cực (Active Learning) và tái huấn luyện mô hình sau này.

5.2. Hướng Phát Triển

Mặc dù đã đạt được những kết quả khả quan, giải pháp công nghệ y tế luôn đòi hỏi sự cải tiến liên tục. Trong tương lai, hệ thống có thể được tiếp tục mở rộng và nâng cấp theo các hướng sau:

- Mở rộng và địa phương hóa tập dữ liệu: Đẩy mạnh thu thập thêm dữ liệu hình ảnh lâm sàng từ các bệnh viện da liễu tại Việt Nam. Quá trình tinh chỉnh (Fine-tuning) với dữ liệu bản địa sẽ giúp AI thích nghi tốt hơn với đặc điểm sắc tố da người châu Á và điều kiện ánh sáng chụp ảnh thực tế bằng điện thoại.
- Phát triển nền tảng ứng dụng di động (Mobile App): Xây dựng phiên bản ứng dụng trên nền tảng Android/iOS nhằm tận dụng camera chất lượng cao của điện thoại thông minh. Điều này sẽ giúp bệnh nhân ở các vùng sâu, vùng xa dễ dàng chụp ảnh tổn thương và nhận tư vấn sàng lọc ban đầu một cách tiện lợi nhất.
- Nghiên cứu các kiến trúc mô hình tiên tiến hơn: Thử nghiệm ứng dụng các mô hình thị giác máy tính thế hệ mới như Vision Transformer (ViT), hoặc kết hợp với Mô hình ngôn ngữ lớn (LLM) để không chỉ trả về nhãn bệnh mà còn tự động sinh ra các đoạn tóm tắt bệnh án và phác đồ điều trị gợi ý dạng văn bản tự nhiên.
- Tích hợp với hệ thống y tế hiện hành (HIS/EMR): Chuẩn hóa các hàm API của MedAI Dermatology theo tiêu chuẩn liên thông dữ liệu y tế quốc tế (như HL7 FHIR). Việc này giúp hệ thống dễ dàng giao tiếp, kết nối và trao đổi hồ sơ bệnh án điện tử trực tiếp với hệ thống quản lý của các bệnh viện lớn.
- Hợp nhất hạ tầng MLOps: Tối ưu hóa đường ống CI/CD, tự động hóa việc lấy dữ liệu phản hồi (Expert Feedback) từ MongoDB để huấn luyện lại mô hình định kỳ, sau đó tự động đóng gói qua Docker và triển khai lên Hugging Face Spaces mà không cần can thiệp thủ công.

TÀI LIỆU THAM KHẢO

[1]. Andre Esteva, Brett Kuprel, Roberto A. Novoa, et al. (2017), Dermatologist-level classification of skin cancer with deep neural networks, Nature.
[2]. Tal Ridnik, Emanuel Ben-Baruch, Asaf Noy, Lihi Zelnik-Manor (2021), Asymmetric Loss for Multi-Label Classification, Proceedings of the IEEE International Conference on Computer Vision (ICCV).
[3]. Mingxing Tan, Quoc V. Le (2019), EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks, Proceedings of the International Conference on Machine Learning (ICML).
[4]. Jayanth Mohan, et al. (2025), Enhancing Skin Disease Classification Leveraging Transformer-Based Architectures and Explainable AI, Computers in Biology and Medicine.
[5]. Harshith S., et al. (2025), A Hybrid AI System for Real-Time Dermatological Condition Recognition using YOLOv8 and EfficientNet-B0, International Journal of Scientific and Advanced Technology (IJSAT).
[6]. Nguyễn Tú Anh (2024), Chẩn đoán bệnh da liễu qua hình ảnh sử dụng mô hình cộng tác của phân đoạn và phân lớp trên bộ dữ liệu ISIC-2018, Luận văn/Đề tài nghiên cứu.

PHỤ LỤC

1. Địa chỉ truy cập hệ thống (Live Demo)

Hệ thống MedAI Dermatology đã được triển khai hoàn chỉnh trên môi trường Internet, cho phép truy cập trực tiếp qua các địa chỉ:

- Giao diện Web (Frontend): khangjv.id.vn (triển khai trên VPS nội địa)
- Máy chủ Backend API: hoangkhang2-medai-dermatology.hf.space (xử lý mô hình AI)
- Tài liệu API (Swagger): hoangkhang2-medai-dermatology.hf.space/docs

2. Kiến trúc triển khai

Hệ thống được xây dựng theo mô hình Client–Server phân tán nhằm tối ưu hiệu năng và khả năng mở rộng:

- Người dùng thao tác trên Frontend, dữ liệu ảnh được gửi qua RESTful API đến Backend.
- Backend thực hiện tiền xử lý (YOLO, DullRazor) và suy luận mô hình AI, sau đó trả kết quả về giao diện.
- Kết quả được lưu trữ trên MongoDB Atlas.
- Các mô hình (EfficientNet, YOLOv8) đã được tích hợp sẵn trong hệ thống.

3. Hướng dẫn triển khai production

3.1 Backend (Hugging Face Spaces)

- Tạo Docker Space và upload mã nguồn (Dockerfile, backend/, preprocessing/).
- Cấu hình biến môi trường:
  + USE_MONGODB, MONGODB_URL, MONGODB_DB_NAME
  + ALLOWED_ORIGINS (cấu hình CORS cho frontend)

3.2 Frontend (VPS)

- Upload thư mục frontend/ lên Web Server (public_html/).
- Cập nhật API URL trong runtime-env.js trỏ về Backend.

4. Cài đặt môi trường local

- Yêu cầu: Python ≥ 3.10, RAM ≥ 8GB
- Chạy bằng Docker (khuyến nghị):

    + docker build -t medai-hf
    + docker run -p 7860:7860 medai-hf
- Chạy thủ công:
    + Backend: uvicorn app.main:app --reload --port 8000
    + Frontend: python -m http.server 3000

5. Hướng dẫn sử dụng hệ thống

- Chẩn đoán: Upload ảnh → hệ thống tiền xử lý → trả kết quả (tên bệnh, độ tin cậy, mức độ nguy hiểm, Grad-CAM).
- Lịch sử: Lưu và tra cứu các lần chẩn đoán.
- Phản hồi chuyên gia: Bác sĩ có thể đánh giá và chỉnh sửa kết quả để cải thiện dữ liệu huấn luyện.
- Dashboard: Theo dõi thống kê bệnh và hiệu suất hệ thống.